

Введение, Марковский процесс принятия решений

Алексей Скрынник

ПЛАН

- 01 Введение
- 02 Многорукие бандиты
- 03 Цепи Маркова
- 04 Марковский процесс с вознаграждениями
- 05 Марковский процесс принятия решений

01



Введение

Идея обучения с подкреплением

Программа учится выбирать действия по их последствиям.


- Выполняет действие и наблюдает результат.
- Получает вознаграждение — численную оценку результата.
- Использует накопленный опыт для следующих решений.
- Учится получать больше вознаграждения за последовательность действий.



Долгосрочное влияние

Ход может казаться невыгодным сейчас, но приближать победу. Обучение помогает понять, какие решения ведут к успеху.

Обучение с подкреплением и другие науки



Психология животных

- **Положительное подкрепление:** добавить приятный стимул, например дать корм после нажатия на рычаг.
- **Отрицательное подкрепление:** убрать неприятный стимул, например выключить громкий звук при нажатии на рычаг.
- Оба вида подкрепления помогают закрепить поведение и используются для обучения животных.
- Боль и голод могут побуждать к действию, но сами по себе не являются отрицательным подкреплением.




Где применяется обучение с подкреплением?

- Игры: го, нарды, видеоигры
- Исследование операций: цены, маршруты доставки
- Управление лифтами
- Управление роботами
- Беспилотный транспорт
- Голосовые и диалоговые системы
- Рассуждения и использование инструментов в LLM
- Энергоэффективность дата-центров
- Автоматическое управление сетями
- Финансы: торговля и исполнение заявок



Исследование операций: маршруты доставки

- **Агент:** система доставки.
- **Среда:** дороги и заказы.
- **Состояние:** машины, загрузка, сроки заказов.
- **Действие:** выбрать следующего клиента.
- **Вознаграждение:** минус затраты на доставку.



Управление роботами

- **Агент:** контроллер робота.
- **Среда:** предметы и рабочая зона.
- **Состояние:** положение робота и предметов.
- **Действие:** двигать суставами и захватом.
- **Вознаграждение:** за успешную установку предмета.



Настольные игры

- **Агент:** шахматная программа.
- **Среда:** доска и соперник.
- **Состояние:** позиция и очередь хода.
- **Действие:** сделать ход.
- **Вознаграждение:** +1 / 0 / -1: победа / ничья / поражение.




Видеоигры

- **Агент:** игрок в Capture the Flag.
- **Среда:** арена, союзники и соперники.
- **Наблюдение:** вид от первого лица, счёт, здоровье.
- **Действие:** двигаться, поворачивать, стрелять.
- **Вознаграждение:** за победу команды.




Обучение с подкреплением для LLM

- **Агент:** языковая модель.
- **Среда:** задачи и проверка решений.
- **Состояние:** запрос и уже написанный текст.
- **Действие:** выбрать следующий токен.
- **Вознаграждение:** правильность и формат ответа.



Финансы: алгоритмическая торговля

- **Агент:** торговый алгоритм.
- **Среда:** рынок.
- **Наблюдение:** цены, заявки, текущий портфель.
- **Действие:** купить, продать или ждать.
- **Вознаграждение:** прибыль с учётом издержек и риска.



В чем сложности обучения с подкреплением?

Обучение с подкреплением объединяет обучение и принятие решений.

- **Стохастическая среда:** одно действие может приводить к разным результатам.
- **Неполная модель:** агенту может быть неизвестна реакция среды.
- **Взаимосвязанные решения:** выбор меняет будущие возможности.
- **Нет учителя:** не требуется указывать правильное действие на каждом шаге.
- **Частичная и отложенная обратная связь:** виден результат выбранного действия, но его значимость может проявиться гораздо позже.

Вознаграждение оценивает результат, но не объясняет, как его добиться.

Где ловить рыбу?

- На выбор три места. У вас **20 забросов**.
- За один заброс можно поймать одну рыбу или остаться без улова.
- Вероятность поймать рыбу зависит от места и заранее неизвестна.
- Цель — поймать как можно больше рыбы.



После двух забросов в точке A вы ничего не поймали. Остаться или сменить место?

02

Многорукие бандиты

Многорукие бандиты

Определение

В задаче **стохастического многорукого бандита** агент на каждом шаге выбирает действие $a_t \in \mathcal{A}$ и наблюдает только его вознаграждение r_t .


- Каждому действию соответствует неизвестное фиксированное распределение вознаграждений; выборки из него независимы.
- $Q(a) = \mathbb{E}[r_t \mid a_t = a]$ — среднее вознаграждение действия.
- Цель — максимизировать $\mathbb{E} \left[\sum_{t=1}^T r_t \right]$.

На рыбалке: $\mathcal{A} = \{A, B, C\}$ — места; $r_t = 1$ за рыбу и 0 без улова. $Q(a)$ — вероятность поймать рыбу в месте a .

Пример: выбор игрового автомата

Та же задача: каждый автомат — отдельное действие.

- На каждом шаге выбираем **один автомат**.
- Получаем случайное **вознаграждение** — выплату автомата.
- Средняя выплата $Q(a)$ каждого автомата неизвестна.
- Цель — максимальная **суммарная выплата** за заданное число попыток.



Ещё один пример — реклама: вместо выплат будем считать клики по объявлениям.

Наш пример: три рекламных объявления

Для каждого посетителя сайт выбирает одно из трёх объявлений.

- **Агент:** система выбора рекламы.
- **Среда:** поток посетителей из аудитории с неизменными характеристиками.
- **Действие:** показать объявление A , B или C .
- **Вознаграждение:** 1 за клик; 0, если клика нет.
- **Неизвестны:** вероятности клика $Q(A)$, $Q(B)$, $Q(C)$.

Упрощения модели

Реакции посетителей независимы. Вероятность клика для каждого объявления постоянна. Текущий выбор не меняет будущую аудиторию и доступные объявления.

Цель — максимизировать ожидаемое суммарное число кликов.

Исследование и использование

Пусть у объявления A пока самая высокая наблюдаемая доля кликов.

- **Использование:** показываем A , опираясь на накопленный опыт.
- **Исследование:** пробуем B или C , чтобы лучше оценить их вероятности клика.
- Видим результат только показанного объявления. Не знаем, кликнул бы этот посетитель на другое.

Одного наблюдения недостаточно

Один раз показали C и получили 0. Истинная вероятность клика всё ещё может быть высокой: даже на хорошее объявление кликают не всегда.

Исследование даёт информацию для будущих решений, но сейчас может уменьшить ожидаемое число кликов.

Учимся по вознаграждениям: жадная стратегия

После 7 показов накопились такие наблюдения:

Действие	Вознаграждения	Число показов	Оценка $\hat{Q}(a)$
A	1, 1, 0, 1	4	$3/4 = 0.75$
B	1, 0	2	$1/2 = 0.50$
C	0	1	$0/1 = 0.00$

- $\hat{Q}(a)$ оценивает неизвестное $Q(a)$ как среднее наблюдаемых вознаграждений.
- **Стратегия** — правило выбора действий. Жадная стратегия выбирает наибольшую оценку: объявление A .

Следующий показ: выбираем A и получаем 0

Обновляем только A : новая оценка $(1 + 1 + 0 + 1 + 0)/5 = 0.60$. Оценки B и C не меняются: 0.50 и 0.00.

Может ли C оказаться лучшим? Из-за одной неудачи жадная стратегия может больше его не пробовать.

ε-жадная стратегия: иногда исследуем

Текущие оценки: $A : 0.60$, $B : 0.50$, $C : 0.00$.

- С вероятностью $1 - \epsilon$ выбираем наибольшую оценку: A .
- С вероятностью ϵ равномерно выбираем одно из трёх действий.

Пример: $\epsilon = 0.3$

В 70% случаев выбираем жадно, в 30% — случайно. Случайный выбор даёт каждому объявлению ещё 10%, в том числе A .


Объявление A	Объявление B	Объявление C
$70\% + 10\% = 80\%$	10%	10%

Так мы продолжаем собирать данные об альтернативных действиях.

От бандитов к обучению с подкреплением

Три идеи для дальнейшего изучения:

- **Агент** выбирает действия с помощью **стратегии**.
- Учится по **вознаграждениям**, стремясь увеличить их сумму.
- Сочетает **исследование** и **использование**.



Дальше: действия меняют ситуацию

Выбор автомата не меняет остальные варианты. Движение робота расходует заряд и меняет его будущие возможности. Для описания ситуации нужно **состояние**.

03




Цепи Маркова

Достаточно ли последнего сигнала?

Как представить состояние агента s_t^a ?


- Последние три события в последовательности.
- Количество появлений света, звонка и рычага.
- Вся последовательность.



Что нужно помнить, чтобы предсказать результат?

Лягушка и три листа кувшинки

- Состояние s_t — текущий лист.
- Начинаем на A , заканчиваем на G .
- Правила прыжков фиксированы: мы только наблюдаем.




Сколько прыжков осталось до G ?

Почему достаточно текущего листа?

На B следующий прыжок ведёт на A или G с вероятностью $1/2$.

Неважно, сколько раз лягушка уже возвращалась на B .

Марковское свойство: при известном состоянии история не меняет распределение следующего состояния.



Марковский процесс

Определение

Марковский процесс с конечным множеством состояний — цепь Маркова, задаваемая парой $\langle S, \mathcal{P} \rangle$:

- ▶ S — множество состояний;
- ▶ $\mathcal{P}_{ss'} = \mathbb{P}(s_{t+1} = s' \mid s_t = s)$ — вероятность перехода.

При известном текущем состоянии история не меняет распределение следующего:

$$\mathbb{P}(s_{t+1} \mid s_t, \dots, s_0) = \mathbb{P}(s_{t+1} \mid s_t).$$


Для лягушки: $S = \{A, B, G\}$; вероятности переходов заданы стрелками.

От рисунка к матрице переходов

$$\mathcal{P}_{ss'} = \mathbb{P}(s_{t+1} = s' \mid s_t = s).$$

$$\mathcal{P} = \begin{array}{c|ccc} & A & B & G \\ \hline A & 0 & 1 & 0 \\ B & 1/2 & 0 & 1/2 \\ G & 0 & 0 & 1 \end{array}$$

Строка — откуда, столбец — куда. Сумма строки равна 1.



Одни правила — разные траектории

Два прыжка

$$A \xrightarrow{1} B \xrightarrow{1/2} G$$

$$\mathbb{P}(\text{этот путь}) = 1 \cdot \frac{1}{2} = \frac{1}{2}.$$

Четыре прыжка

$$A \xrightarrow{1} B \xrightarrow{1/2} A \xrightarrow{1} B \xrightarrow{1/2} G$$

$$\mathbb{P}(\text{этот путь}) = 1 \cdot \frac{1}{2} \cdot 1 \cdot \frac{1}{2} = \frac{1}{4}.$$

Над стрелками — вероятности. Для одного пути перемножаем их.

Возвратов на A может быть больше: число прыжков случайно.

04

Марковский процесс с вознаграждениями

Марковский процесс с вознаграждениями

Определение

Марковский процесс с вознаграждениями — кортеж $\langle S, \mathcal{P}, \mathcal{R}, \gamma \rangle$, где

- ▶ S и $\mathcal{P}$ — состояния и переходы цепи Маркова;
- ▶ $\mathcal{R}(s) = \mathbb{E}[r_{t+1} \mid s_t = s]$ — ожидаемое вознаграждение за переход из s ;
- ▶ $\gamma \in [0, 1]$ — коэффициент дисконтирования.

Для лягушки: сохраняем переходы и назначаем -1 за каждый прыжок:

$$\mathcal{R}(A) = \mathcal{R}(B) = -1, \quad \mathcal{R}(G) = 0.$$

Сначала используем $\gamma = 1$: все вознаграждения имеют одинаковый вес.

Каждый прыжок даёт -1

Те же переходы. Добавим вознаграждение $r_{t+1} = -1$ за каждый прыжок, включая последний.

$$A \xrightarrow{-1} B \xrightarrow{-1} G$$

$$G_0 = -1 - 1 = -2.$$

$$A \xrightarrow{-1} B \xrightarrow{-1} A \xrightarrow{-1} B \xrightarrow{-1} G$$

$$G_0 = -1 - 1 - 1 - 1 = -4.$$

Вознаграждение — за один переход. **Отдача** G_t — сумма будущих вознаграждений до конца эпизода.

Сколько прыжков осталось в среднем?


Отдача одного эпизода случайна: $-2, -4, -6, \dots$

Полезность состояния — ожидаемая отдача при старте из него:

$$V(s) = \mathbb{E}[G_t \mid s_t = s].$$

Для лягушки $V(s)$ — минус
ожидаемое число прыжков до G .

$V(G) = 0$: путь уже закончен.




Один прыжок сейчас, затем оставшийся путь

Из B сначала получаем -1 .

Затем с вероятностью $1/2$:

- возвращаемся на A : остаётся $V(A)$;
- достигаем G : остаётся 0 .



$$V(B) = \underbrace{-1}_{\text{сейчас}} + \underbrace{\frac{1}{2}V(A) + \frac{1}{2} \cdot 0}_{\text{ожидаемая отдача после прыжка}}.$$

Уравнение Беллмана

Определение

Уравнение Беллмана связывает полезность текущего состояния с наградой за ближайший переход и полезностями следующих состояний. При $\gamma = 1$:

$$V(s) = \underbrace{\mathcal{R}(s)}_{\text{ожидаемая награда сейчас}} + \underbrace{\sum_{s' \in S} \mathcal{P}_{ss'} V(s')}_{\text{ожидаемая полезность после перехода}}.$$

В основе тот же шаг, что и в примере с лягушкой:

$$G_t = r_{t+1} + G_{t+1}.$$

Зачем это нужно? Вместо перебора всех траекторий составляем систему уравнений для $V(s)$.


Уравнение Беллмана: найдём полезности

$$V(A) = -1 + V(B),$$

$$V(B) = -1 + \frac{1}{2}V(A),$$

$$V(G) = 0.$$

$$V(A) = -4, \quad V(B) = -3.$$



Из A остаётся в среднем четыре прыжка, из B — три.

Дисконтирование: меньший вес далёкого будущего

Теперь введём коэффициент $\gamma \in [0, 1]$:

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots .$$

Для четырёх прыжков при $\gamma = 0.9$:

$$G_0 = -1 - 0.9 - 0.81 - 0.729 = -3.439.$$

В уравнении Беллмана будущая полезность тоже получает вес γ :

$$V(s) = \mathcal{R}(s) + \gamma \sum_{s'} \mathcal{P}_{ss'} V(s').$$

При $\gamma = 1$ возвращаемся к предыдущему расчёту.

От предсказания к управлению

- **Цепь Маркова:** предсказываем, куда попадёт лягушка.
- **Процесс с вознаграждениями:** предсказываем отдачу из каждого состояния.

До сих пор правила прыжков были фиксированы.

Что изменится, если агент сможет выбирать действие?

От выбора будут зависеть переходы и вознаграждения. Получим **марковский процесс принятия решений (МППР)**.

05

Марковский процесс принятия решений

Марковский процесс принятия решений

Определение

Марковский процесс принятия решений (МППР) – это кортеж $\langle S, A, \mathcal{P}, \mathcal{R}, \gamma \rangle$, где

- S – конечное множество состояний,
- A – конечное множество действий,
- $\mathcal{P}$ – матрица вероятностей переходов:

$$\mathcal{P}_{ss'}^a = \mathbb{P}[s_{t+1} = s' | s_t = s, a_t = a],$$

- $\mathcal{R}$ – функция вознаграждения $\mathcal{R}_s^a = \mathbb{E}[r_{t+1} | s_t = s, a_t = a]$,
- $\gamma \in [0, 1]$ – дисконтирующий множитель.

Стратегии

Определение


Стратегией π будем называть вероятностное распределение на множестве действий при текущем состоянии s :

$$\pi(a|s) = \mathbb{P}[a_t = a | s_t = s]$$

- Стратегия полностью определяет поведение агента.
- МППР стратегии зависят от текущего состояния.
- Стратегии стационарны (не зависят от времени):

$$a_t \sim \pi(\cdot | s_t), \forall t \geq 0.$$


Пример 1: Алиса в Стране чудес



Пример 2: Лабиринт

Цель: добраться до сыра за меньшее число шагов.


- **Состояние:** текущая клетка.
- **Действия:** $\uparrow, \downarrow, \leftarrow, \rightarrow$.
- **Вознаграждение:** -1 за попытку шага.
- У стены мышь остаётся на месте.
- На клетке с сыром эпизод заканчивается.



Лабиринт: стратегия

Стратегия π : какое действие выбрать в каждой клетке.


- Стрелка показывает выбранное действие.
- Стратегия задаёт поведение на всей карте.



Лабиринт: полезность состояния

Полезность $V^\pi(s)$: сколько суммарного вознаграждения осталось получить.

- Следуем показанной стратегии;
 $\gamma = 1$.
- Каждый шаг даёт -1 .
- Из A до сыра три шага:
$$V^\pi(A) = -3, \quad V^\pi(G) = 0.$$



Лабиринт: дисконтирование


Из S к сыру можно пройти двумя маршрутами. Каждый шаг по-прежнему даёт -1 .

$$G_n = - \sum_{k=0}^{n-1} \gamma^k$$

11 шагов 15 шагов

$$\begin{array}{rcc} \gamma = 1 & -11 & -15 \\ \gamma = 0.9 & \approx -6.86 & \approx -7.94 \\ \gamma = 0.5 & \approx -1.9990 & \approx -1.9999 \end{array}$$

При малом γ отдачи почти
одинаковы: далёкие штрафы имеют
малый вес.



Вопросы?