

Метод Монте-Карло, Временные различия

Алексей Скрынник

ПЛАН


- 01 Метод Монте-Карло
- 02 Метод временных различий
- 03 Q-обучение
- 04 Обобщенный подход
- 05 Переход между TD и МК методами

01

Метод Монте-Карло

Обновление динамического программирования

Какое основное ограничение есть у методов динамического программирования?



Итерация по полезностям

Вход: порог сходимости θ , коэффициент дисконтирования γ

```
1: Инициализировать  $V(s)$  произвольно для всех  $s \in \mathcal{S}$ 
2: repeat
3:    $\Delta \leftarrow 0$ 
4:   for каждого  $s \in \mathcal{S}$  do
5:      $v \leftarrow V(s)$ 
6:      $V(s) \leftarrow \max_a \sum_{s',r} p(s', r \mid s, a) [r + \gamma V(s')]$  ▷ лучшее действие по модели
7:      $\Delta \leftarrow \max(\Delta, |v - V(s)|)$ 
8:   end for
9: until  $\Delta < \theta$  ▷ все оценки почти перестали меняться

10:  $\pi(s) \leftarrow \arg \max_a \sum_{s',r} p(s', r \mid s, a) [r + \gamma V(s')]$  ▷ жадная стратегия
11: return  $\pi, V$ 
```

Ограничение — нам нужна внутренняя информация о среде для поиска стратегии

Монте-Карло подход к обучению с подкреплением

1. Будем оценивать стратегию напрямую по эпизодам взаимодействия со средой.
2. Используем безмодельный подход (model-free): модель переходов МППР и функция вознаграждения не известны.
3. Будем проводить обучение по полным эпизодам.
4. Подход Монте-Карло (МК) использует максимально простую идею: полезность равна средней отдаче.

Монте-Карло оценка стратегии

- Цель: построить V^π по эпизодам взаимодействия по стратегии π :

$$s_0, a_0, r_1, s_1, a_1, r_2, \dots, s_T$$

- *Отдача* (return) — это суммарное вознаграждение:

$$G_t = r_{t+1} + \gamma r_{t+2} + \dots + \gamma^{T-t-1} r_T$$

- *Функция полезности* — это матожидание отдачи:

$$V^\pi(s) = \mathbb{E}_\pi[G_t | s_t = s]$$

- Монте-Карло оценка стратегии использует **эмпирическое среднее** отдачи вместо матожидания.

Монте-Карло оценка стратегии с первым посещением

Оцениваем состояние s :

➤ для **первого** по времени посещения состояния s в эпизоде:

➤ $N(s) \leftarrow N(s) + 1$

➤ $S(s) \leftarrow S(s) + G_t$

Полезность оцениваем как среднюю отдачу: $V(s) = S(s)/N(s)$

По закону больших чисел:

$$V(s) \xrightarrow{N(s) \rightarrow \infty} V^\pi(s)$$

Несмещенная, состоятельная оценка с высокой дисперсией.

Монте-Карло оценка стратегии с каждым посещением

Оцениваем состояние s :

➤ для **каждого** по времени посещения состояния s в эпизоде:

➤ $N(s) \leftarrow N(s) + 1$

➤ $S(s) \leftarrow S(s) + G_t$

Полезность оцениваем как среднюю отдачу: $V(s) = S(s)/N(s)$

По закону больших чисел:

$$V(s) \xrightarrow{N(s) \rightarrow \infty} V^\pi(s)$$

Состоятельная оценка; на конечной выборке может быть смещенной. Использует все посещения, но отдачи внутри эпизода коррелированы.

Пример: блек-джек

Состояние: $10 \times 10 \times 2 = 200$

Сумма игрока 12–21

Открытая карта дилера туз, 2, ..., 10

Туз, считаемый за 11 да / нет

Туз считается за 11, если нет перебора; иначе за 1.

При сумме < 12 игрок автоматически берёт карту.

Два действия

Hit взять карту

Stick остановиться

Вознаграждение

$$r = \begin{cases} +1, & \text{победа,} \\ 0, & \text{ничья,} \\ -1, & \text{поражение.} \end{cases}$$




Стратегия дилера

Всегда берет карту при < 17 .


Блек-джек: оценка фиксированной стратегии

Фиксируем π : брать карту при сумме < 16 , иначе остановиться.


10,000 episodes



100,000 episodes



1,000,000 episodes



Среднее приращений

Как учесть новое наблюдение?

- Уже знаем среднее μ_{k-1} по $k - 1$ наблюдениям.
- Получаем новое значение x_k .
- Сдвигаем среднее к x_k на долю $1/k$ от разности $x_k - \mu_{k-1}$.

Храним только среднее и число наблюдений.

$$\begin{aligned}\mu_k &= \frac{1}{k} \sum_{j=1}^k x_j \\ &= \frac{1}{k} \left(x_k + \sum_{j=1}^{k-1} x_j \right) \\ &= \frac{x_k + (k-1)\mu_{k-1}}{k} \\ &= \mu_{k-1} + \frac{1}{k}(x_k - \mu_{k-1})\end{aligned}$$

Монте-Карло для приращений

- Обновим $V(s)$ с приращением (incrementally) для эпизода $s_0, a_0, r_1, s_1, \dots, s_T$
- Для каждого состояния s_t с отдачей G_t :

$$N(s_t) \leftarrow N(s_t) + 1,$$

$$V(s_t) \leftarrow V(s_t) + \frac{1}{N(s_t)}(G_t - V(s_t))$$

- В нестационарных задачах может быть полезно отслеживать текущее среднее:

$$V(s_t) \leftarrow V(s_t) + \alpha(G_t - V(s_t))$$

02




Метод временных различий

Как учиться, не дожидаясь конца эпизода?

Идея временных различий (TD)

1. Наблюдаем один переход и награду r_{t+1} .
2. Оцениваем оставшуюся отдачу через текущую $V(s_{t+1})$.
3. Используем их сумму с дисконтированием, чтобы обновить $V(s_t)$.



Используем текущую оценку для обновления другой — это **бутстреп**.

Монте-Карло и временные различия

- Цель: построить V^π интерактивно (online) по эпизодам взаимодействия по стратегии π
- Монте-Карло с каждым посещением для приращений: обновляем $V(s_t)$ на основе текущей отдачи G_t

$$V(s_t) \leftarrow V(s_t) + \alpha(G_t - V(s_t))$$

- Самый простой подход временных различий: TD(0):

- обновляем на основе *ожидаемой* отдачи $r_{t+1} + \gamma V(s_{t+1})$

$$V(s_t) \leftarrow V(s_t) + \alpha(r_{t+1} + \gamma V(s_{t+1}) - V(s_t)),$$

- $r_{t+1} + \gamma V(s_{t+1})$ называется **TD показателем**,
 - $\delta_t = r_{t+1} + \gamma V(s_{t+1}) - V(s_t)$ называется **TD ошибкой**

Поездка домой: прогноз меняется по дороге

Каждый день вы едете из офиса домой и учитесь предсказывать время в пути.


1. В офисе вы предполагаете: дорога займёт **30 минут**.
2. Через **5 минут** начинается дождь. Теперь вы ожидаете **ещё 35 минут** пути.

Можно ли уже сейчас уточнить прогноз, сделанный в офисе?

Поездка домой: сколько ещё ехать?

$V(s)$ — оценка **оставшегося времени до дома**.

Здесь r — минуты на очередной участок пути, $\gamma = 1$. Предсказываем время, не выбираем маршрут.



Первый переход: прошло 5 минут, начался дождь. Теперь ожидаем ещё 35 минут до дома.

$$\underbrace{5}_{\text{уже прошли}} + \underbrace{35}_{\text{ожидаем впереди}} = \underbrace{40 \text{ МИН}}_{\text{новая оценка всей поездки}} .$$

Обновить сейчас или дождаться дома?

Сравним обновление одной оценки: $V(\text{офис}) = 30$ минут. Возьмём $\alpha = 0.1$.

TD: через 5 минут

Прошло 5 минут, впереди ещё 35 по текущей оценке.

$$r_1 + V(s_1) = 5 + 35 = 40$$

Обновляем оценку для офиса:

$$30 + 0.1(40 - 30) = 31$$

МК: после возвращения домой

Вся поездка заняла 43 минуты. Теперь знаем полную отдачу.

$$G_0 = 43$$

Обновляем оценку для офиса:

$$30 + 0.1(43 - 30) = 31.3$$

TD использует следующий прогноз, МК — фактическое время всей поездки.

Смещенность и дисперсия

Оцениваем $V^\pi(s)$ при $s_t = s$; действия выбираются по π .

- МК: отдача $G_t = r_{t+1} + \gamma r_{t+2} + \dots + \gamma^{T-t-1} r_T$ — **несмещенная** оценка.
- TD с истинной полезностью: $r_{t+1} + \gamma V^\pi(s_{t+1})$ — тоже **несмещенная** оценка.
- TD с текущей оценкой: $r_{t+1} + \gamma V(s_{t+1})$ — **в общем случае смещенная** оценка.
- Дисперсия TD показателя **обычно ниже**, чем у МК отдачи: используем один переход вместо полного продолжения эпизода. Для произвольной V гарантии нет.
- **Смещение показателя не означает ошибку в пределе:** табличный TD сходится к V^π при бесконечных посещениях оцениваемых состояний и корректном выборе скорости обучения.

Преимущества и недостатки


Монте-Карло

- Обновление в конце эпизода.
- Оценка по полной отдаче G_t .
- Несмещенная оценка, обычно высокая дисперсия.



Временные различия

- Обновление на каждом шаге.
- Оценка по $r_{t+1} + \gamma V(s_{t+1})$.
- Смещенная оценка и более низкая дисперсия.

Пример: случайное блуждание



Влево / вправо с вероятностью $1/2$; остальные награды 0; $\gamma = 1$.



Одинаковый опыт — одинаковые оценки?

Получат ли МК и TD одинаковые V , если дать им одни и те же эпизоды?

Зафиксируем конечный набор эпизодов по π . Новые данные не добавляем — учимся только на этом наборе.

МК усредняет отдачи

$$G_t$$

TD усредняет показатели

$$r_{t+1} + \gamma V(s_{t+1})$$

Пакетный режим: за проход вычисляем все показатели с неизменной V , затем одновременно заменяем $V(s)$ средними по посещениям каждого состояния. Повторяем до стабилизации.

Для терминальных состояний $V = 0$.

Пример: АВ

Два состояния А, В; нет
дисконтирования, 8 эпизодов опыта:

А, 0, В, 0

В, 1

В, 1

В, 1

В, 1

В, 1

В, 1

В, 0

Применяем синхронные пакетные
обновления до стабилизации. Какие
значения получим для $V(A)$ и $V(B)$ в МК
и TD(0)?

Пример: АВ

Два состояния А, В; нет дисконтирования, 8 эпизодов опыта:

А, 0, В, 0

В, 1

В, 1

В, 1


В, 1

В, 1

В, 1

В, 0

Применяем синхронные пакетные обновления до стабилизации. Какие значения получим для $V(A)$ и $V(B)$ в МК и TD(0)?



$$V(B) = \frac{6}{8} = 0.75$$

$$\text{МК: } V(A) = 0$$

$$\text{TD: } V(A) = 0.75$$

Почему МК и TD дали разные ответы?

МК: что произошло после A?

В данных есть только один эпизод с A:

$$A \xrightarrow{0} B \xrightarrow{0} T$$

Его полная отдача равна нулю.

$$V_{\text{МК}}(A) = 0$$

TD: куда мы попали из A?

Из A попали в B с наградой 0. По всем восьми посещениям B:

$$V(B) = \frac{6}{8} = 0.75$$

В марковской модели не важно, как мы пришли в B.

$$V_{\text{TD}}(A) = 0 + V(B) = 0.75$$

Пакетный TD оценивает **марковский процесс по данным**: частоты переходов и средние награды задают его модель.

03

Q-обучение

On-policy и off-policy

- μ — **поведенческая стратегия**: выбирает действия и собирает опыт.
- π — **целевая стратегия**: её полезность оцениваем.

On-policy

$$\mu = \pi$$

Оцениваем ту же стратегию, по которой действуем.

Off-policy


$$\mu \neq \pi$$

Действуем по одной стратегии, оцениваем другую.

Пример: Q-learning действует с исследованием, а обновление использует жадный выбор. Это off-policy даже при обучении по только что полученному переходу.

Напоминание: Обобщенные итерации по стратегиям

- **Итеративная оценка стратегии** — вычисление V^π
- **Улучшение стратегии** — генерация $\pi' \geq \pi$



Использование функции полезности действий

- Жадное улучшение стратегии по $V(s)$ требует знания модели МППР:

$$\pi'(s) \in \arg \max_{a \in A} \left[\mathcal{R}_s^a + \gamma \sum_{s'} \mathcal{P}_{ss'}^a V(s') \right]$$

- Жадное улучшение стратегии по $Q(s, a)$ **не требует** знания модели:

$$\pi'(s) \in \arg \max_{a \in A} Q(s, a)$$


Пример жадного выбора действий

$Q(a)$ — средняя награда за выбор двери a .

Пробуем каждую дверь, затем выбираем жадно:

Дверь	Награда	Новая оценка
Левая	0	$Q(\text{left}) = 0$
Правая	+1	$Q(\text{right}) = 1$
Правая	+2	$Q(\text{right}) = \frac{1+2}{2} = 1.5$
Правая	+2	$Q(\text{right}) = \frac{1+2+2}{3} \approx 1.67$

А что, если с левой дверью нам просто не повезло в первый раз?



Исследование

- Простейшая идея, обеспечивающая постоянное исследование среды
- При $\epsilon > 0$ все действия выбираются с ненулевой вероятностью
- С вероятностью $1 - \epsilon$ выбираем действие жадно
- С вероятностью ϵ выбираем действие равновероятно из всех доступных

Выберем одно $a^* \in \arg \max_{b \in A} Q(s, b)$. Тогда

$$\pi(a \mid s) = \begin{cases} 1 - \epsilon + \epsilon/m, & a = a^*, \\ \epsilon/m, & a \neq a^*. \end{cases}$$

где $m = |A|$ — количество доступных действий, $0 \leq \epsilon \leq 1$.

Q-обновление

$$Q^{new}(s_t, a_t) \leftarrow (1 - \underbrace{\alpha}_{\text{скор. обуч.}}) \cdot \underbrace{Q(s_t, a_t)}_{\text{тек. значение}} + \underbrace{\alpha}_{\text{скор. обуч.}} \cdot \left(\underbrace{r_{t+1}}_{\text{вознагр.}} + \underbrace{\gamma}_{\text{дисконтирование}} \cdot \underbrace{\max_a Q(s_{t+1}, a)}_{\text{оценка будущего}} \right)$$

Зачем нужно off-policy обучение?

Оцениваем $V^\pi(s)$ или $Q^\pi(s, a)$ для целевой стратегии π , используя переходы, собранные поведенческой стратегией μ :

$$(s_t, a_t, r_{t+1}, s_{t+1}), \quad a_t \sim \mu(\cdot \mid s_t).$$

- Учиться на опыте человека или других агентов.
- Повторно использовать опыт предыдущих стратегий.
- Учиться жадной стратегии, продолжая исследовать среду.

Q-обучение

- Выполняем действие $a_t \sim \mu(\cdot \mid s_t)$ и наблюдаем r_{t+1}, s_{t+1} .
- Для обновления выбираем **жадное** действие в следующем состоянии:

$$a' \in \arg \max_{a \in A} Q(s_{t+1}, a).$$

- Обновляем $Q(s_t, a_t)$, используя значение этого действия:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha(r_{t+1} + \gamma Q(s_{t+1}, a') - Q(s_t, a_t))$$

Off-policy управление: Q-обучение

- По мере обновления Q улучшаем целевую и поведенческую стратегии.
- Целевая стратегия π выбирает жадное действие:

$$\pi(s_{t+1}) \in \arg \max_{a'} Q(s_{t+1}, a')$$

- Поведенческая стратегия μ продолжает исследовать среду, например, выбирая действия ϵ -жадно по Q .
- Показатель Q-обучения использует максимальную оценку:

$$r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a').$$

Псевдокод алгоритма Q-обучения

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

Псевдокод алгоритма Q-обучения

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

1: $Q[s, a] \leftarrow 0 \quad \forall s \in S, a \in A$

▷ таблица значений полезности действий

Псевдокод алгоритма Q-обучения

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

1: $Q[s, a] \leftarrow 0 \quad \forall s \in S, a \in A$

▷ таблица значений полезности действий

2: **for** всех эпизодов **do**

14: **end for**

Псевдокод алгоритма Q-обучения

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

1: $Q[s, a] \leftarrow 0 \quad \forall s \in S, a \in A$

▷ таблица значений полезности действий

2: **for** всех эпизодов **do**

3: $s \leftarrow$ начальное состояние

14: **end for**

Псевдокод алгоритма Q-обучения

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

```
1:  $Q[s, a] \leftarrow 0 \quad \forall s \in S, a \in A$  ▷ таблица значений полезности действий
2: for всех эпизодов do
3:    $s \leftarrow$  начальное состояние
4:   for всех шагов эпизода do
5:      $a \leftarrow \epsilon$ -жадная  $\pi(s)$  ▷ продолжаем исследовать
6:      $r, s' \leftarrow$  применение  $a$ 
7:     if  $s'$  терминальное then
8:        $Q[s, a] \leftarrow Q[s, a] + \alpha(r - Q[s, a])$  ▷ будущих наград нет
9:       break ▷ конец эпизода
10:    end if
11:     $Q[s, a] \leftarrow Q[s, a] + \alpha(r + \gamma \max_{a'} Q[s', a'] - Q[s, a])$  ▷ жадное продолжение
12:     $s \leftarrow s'$ 
13:  end for
14: end for
```

От Q-обучения к SARSA

Оба метода выполняют переход (s, a, r, s') . Отличается только оценка продолжения.

Q-обучение

$$r + \gamma \max_{a'} Q(s', a')$$

Предполагает, что дальше выберем жадное действие.

Off-policy: действуем с исследованием, оцениваем жадное продолжение.

SARSA

$$r + \gamma Q(s', a'), \quad a' \sim \pi(\cdot \mid s')$$

Сначала выбирает действие a' , которое действительно выполнит следующим.

On-policy: оцениваем продолжение с тем же исследованием.

В псевдокоде заменяем $\max_{a'} Q(s', a')$ на выбранное $Q(s', a')$ и переносим a' на следующий шаг.

Псевдокод алгоритма SARSA

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

Псевдокод алгоритма SARSA

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

1: $Q[s, a] \leftarrow 0 \quad \forall s \in S, a \in A$

▷ таблица значений полезности действий

Псевдокод алгоритма SARSA

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

1: $Q[s, a] \leftarrow 0 \quad \forall s \in S, a \in A$

▷ таблица значений полезности действий

2: **for** всех эпизодов **do**

15: **end for**

Псевдокод алгоритма SARSA

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

1: $Q[s, a] \leftarrow 0 \quad \forall s \in S, a \in A$

▷ таблица значений полезности действий

2: **for** всех эпизодов **do**

3: $s \leftarrow$ начальное состояние

15: **end for**

Псевдокод алгоритма SARSA

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

1: $Q[s, a] \leftarrow 0 \quad \forall s \in S, a \in A$

▷ таблица значений полезности действий

2: **for** всех эпизодов **do**

3: $s \leftarrow$ начальное состояние

4: $a \leftarrow \epsilon$ -жадная $\pi(s)$


15: **end for**

Псевдокод алгоритма SARSA

Вход: среда $\langle S, A \rangle$, γ , ϵ , шаг обучения α

```
1:  $Q[s, a] \leftarrow 0 \quad \forall s \in S, a \in A$  ▷ таблица значений полезности действий
2: for всех эпизодов do
3:    $s \leftarrow$  начальное состояние
4:    $a \leftarrow \epsilon$ -жадная  $\pi(s)$ 
5:   for всех шагов эпизода do
6:      $r, s' \leftarrow$  применение  $a$ 
7:     if  $s'$  терминальное then
8:        $Q[s, a] \leftarrow Q[s, a] + \alpha(r - Q[s, a])$  ▷ будущих наград нет
9:       break ▷ конец эпизода
10:    end if
11:     $a' \leftarrow \epsilon$ -жадная  $\pi(s')$  ▷ это действие выполним следующим
12:     $Q[s, a] \leftarrow Q[s, a] + \alpha(r + \gamma Q[s', a'] - Q[s, a])$  ▷ с учётом исследования
13:     $s \leftarrow s', a \leftarrow a'$ 
14:  end for
15: end for
```


Пример задачи: Cliff Walking



Дальше от обрыва / Кратчайший путь

Шаг: -1 . Обрыв: -100 и возврат в S.



Эпизод заканчивается только в G.



Отдача во время обучения с исследованием ($\epsilon = 0.1$).

Почему короткий путь даёт меньшую отдачу?

Отключим исследование после обучения ($\epsilon = 0$). Маршруты первого запуска:



SARSA

$$r + \gamma Q(s', a'), \quad a' \sim \mu(\cdot \mid s')$$

Учитывает возможные будущие случайные действия.

Q-learning

$$r + \gamma \max_{a'} Q(s', a')$$

Оценивает жадное продолжение.

При $\epsilon = 0.1$ над обрывом случайный шаг вниз имеет вероятность $\epsilon/4 = 2.5\%$: штраф -100 и возврат в S. Случайные падения снижают среднюю отдачу короткого маршрута.

04




Обобщенный подход

Монте-Карло обновление

МС обновление использует полный путь от корня до терминального состояния (одна выборочная траектория).


$$V(s_t) \leftarrow V(s_t) + \alpha(G_t - V(s_t)).$$



Обновление временных различий

TD обновление использует только один шаг: от s_t к s_{t+1} с вознаграждением r_{t+1} .


$$V(s_t) \leftarrow V(s_t) + \alpha (r_{t+1} + \gamma V(s_{t+1}) - V(s_t)).$$



Обновление динамического программирования


DP обновление использует полное ожидание по всем возможным действиям и переходам.

$$V(s_t) \leftarrow \mathbb{E}_{\pi} [r_{t+1} + \gamma V(s_{t+1})].$$



Обобщенный подход к обучению с подкреплением

- Методы обучения с подкреплением различаются по глубине и ширине обновлений.
- По вертикали — глубина бутстрепа: от одного шага (TD) до полного эпизода (MC).
- По горизонтали — ширина выборки обновления: от одной траектории (TD) до полного обхода по всем (DP).



05

Переход между TD и МК методами

От одного шага к полному эпизоду

Соберём n наград, затем оценим оставшуюся отдачу через V :

$$G_t^{(n)} = \underbrace{\sum_{k=1}^n \gamma^{k-1} r_{t+k}}_{\text{наблюдаемые награды}} + \underbrace{\gamma^n V(s_{t+n})}_{\text{бутстреп}}, \quad t+n < T.$$

- $n = 1$: показатель TD(0), $r_{t+1} + \gamma V(s_{t+1})$.
- Если дошли до конца эпизода ($t+n \geq T$), используем полную отдачу: $G_t^{(n)} = G_t$, без бутстрепа.

Обновление по n -шаговой отдаче:

$$V(s_t) \leftarrow V(s_t) + \alpha (G_t^{(n)} - V(s_t)).$$

λ -отдача: объединяем несколько прогнозов

До конца эпизода осталось **три шага**. Построим три оценки одной отдачи:

$$\text{Один шаг: } G_t^{(1)} = r_{t+1} + \gamma V(s_{t+1}),$$

$$\text{Два шага: } G_t^{(2)} = r_{t+1} + \gamma r_{t+2} + \gamma^2 V(s_{t+2}),$$

$$\text{Весь эпизод: } G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3}.$$

λ -отдача — взвешенное среднее этих прогнозов.

При $\lambda = 0.5$ каждому прогнозу отдаём половину оставшегося веса. Последнему — весь остаток:

$$G_t^{\lambda=0.5} = \underbrace{\frac{1}{2}G_t^{(1)}}_{\text{один шаг}} + \underbrace{\frac{1}{4}G_t^{(2)}}_{\text{два шага}} + \underbrace{\frac{1}{4}G_t}_{\text{весь эпизод}}.$$

$\lambda = 0$: только один шаг (TD). $\lambda = 1$: только полная отдача (МК).

λ -отдача: общая формула

До конца эпизода осталось $h = T - t$ шагов, $\lambda \in [0, 1]$.

Каждому промежуточному прогнозу отдаём долю $1 - \lambda$ оставшегося веса; долю λ передаём дальше.

$$G_t^\lambda = \sum_{n=1}^{h-1} \underbrace{(1 - \lambda)\lambda^{n-1}}_{\text{вес } n\text{-шаговой отдачи}} G_t^{(n)} + \underbrace{\lambda^{h-1}}_{\text{оставшийся вес}} G_t.$$


Для трёх оставшихся шагов:

$$G_t^\lambda = (1 - \lambda)G_t^{(1)} + \lambda(1 - \lambda)G_t^{(2)} + \lambda^2G_t.$$

При $\lambda = 0.5$ получаем веса $1/2, 1/4, 1/4$ из примера.

Сумма весов равна 1: это взвешенное среднее отдач.

Следы приемлимости (Eligibility Traces)



Алгоритм TD(λ)

Смесь TD-обновлений и МК, контролируемая параметром λ . $\lambda = 0$ — TD, $\lambda = 1$ — МК.

Вход: среда $\langle S, A \rangle$, фиксированная стратегия π , шаг обучения α , коэффициент дисконтирования γ , параметр λ

Алгоритм TD(λ)

Смесь TD-обновлений и МК, контролируемая параметром λ . $\lambda = 0$ — TD, $\lambda = 1$ — МК.

Вход: среда $\langle S, A \rangle$, фиксированная стратегия π , шаг обучения α , коэффициент дисконтирования γ , параметр λ

1: $V[s] \leftarrow 0 \quad \forall s \in S$

▷ терминальные значения оставляем нулевыми

Алгоритм TD(λ)

Смесь TD-обновлений и МК, контролируемая параметром λ . $\lambda = 0$ — TD, $\lambda = 1$ — МК.

Вход: среда $\langle S, A \rangle$, фиксированная стратегия π , шаг обучения α , коэффициент дисконтирования γ , параметр λ

1: $V[s] \leftarrow 0 \quad \forall s \in S$

▷ терминальные значения оставляем нулевыми

2: **for** всех эпизодов **do**

19: **end for**

Алгоритм TD(λ)

Смесь TD-обновлений и МК, контролируемая параметром λ . $\lambda = 0$ — TD, $\lambda = 1$ — МК.

Вход: среда $\langle S, A \rangle$, фиксированная стратегия π , шаг обучения α , коэффициент дисконтирования γ , параметр λ

1: $V[s] \leftarrow 0 \quad \forall s \in S$

▷ терминальные значения оставляем нулевыми

2: **for** всех эпизодов **do**

3: $s \leftarrow$ начальное состояние

4: $E[x] \leftarrow 0 \quad \forall x \in S$

▷ прошлый эпизод не влияет на новый

19: **end for**

Алгоритм TD(λ)

Смесь TD-обновлений и МК, контролируемая параметром λ . $\lambda = 0$ — TD, $\lambda = 1$ — МК.

Вход: среда $\langle S, A \rangle$, фиксированная стратегия π , шаг обучения α , коэффициент дисконтирования γ , параметр λ

1: $V[s] \leftarrow 0 \quad \forall s \in S$

▷ терминальные значения оставляем нулевыми

2: **for** всех эпизодов **do**

3: $s \leftarrow$ начальное состояние

4: $E[x] \leftarrow 0 \quad \forall x \in S$

▷ прошлый эпизод не влияет на новый

5: **for** всех шагов эпизода **do**

18: **end for**

19: **end for**

Алгоритм TD(λ)

Смесь TD-обновлений и МК, контролируемая параметром λ . $\lambda = 0$ — TD, $\lambda = 1$ — МК.

Вход: среда $\langle S, A \rangle$, фиксированная стратегия π , шаг обучения α , коэффициент дисконтирования γ , параметр λ

```
1:  $V[s] \leftarrow 0 \ \forall s \in S$ 
2: for всех эпизодов do
3:    $s \leftarrow$  начальное состояние
4:    $E[x] \leftarrow 0 \ \forall x \in S$ 
5:   for всех шагов эпизода do
6:      $a \sim \pi(\cdot \mid s)$ 
7:      $r, s' \leftarrow$  применение  $a$ 
```

▷ терминальные значения оставляем нулевыми

▷ прошлый эпизод не влияет на новый

▷ оцениваем фиксированную стратегию

```
18:   end for
19: end for
```

Алгоритм TD(λ)

Смесь TD-обновлений и МК, контролируемая параметром λ . $\lambda = 0$ — TD, $\lambda = 1$ — МК.

Вход: среда $\langle S, A \rangle$, фиксированная стратегия π , шаг обучения α , коэффициент дисконтирования γ , параметр λ

```
1:  $V[s] \leftarrow 0 \ \forall s \in S$ 
2: for всех эпизодов do
3:    $s \leftarrow$  начальное состояние
4:    $E[x] \leftarrow 0 \ \forall x \in S$ 
5:   for всех шагов эпизода do
6:      $a \sim \pi(\cdot \mid s)$ 
7:      $r, s' \leftarrow$  применение  $a$ 
8:      $\delta \leftarrow r + \gamma V[s'] - V[s]$ 
9:      $E[s] \leftarrow E[s] + 1$ 
18:   end for
19: end for
```

▷ терминальные значения оставляем нулевыми

▷ прошлый эпизод не влияет на новый

▷ оцениваем фиксированную стратегию

▷ насколько уточнилась оценка отдачи

▷ увеличиваем вес посещённого состояния

Алгоритм TD(λ)

Смесь TD-обновлений и МК, контролируемая параметром λ . $\lambda = 0$ — TD, $\lambda = 1$ — МК.

Вход: среда $\langle S, A \rangle$, фиксированная стратегия π , шаг обучения α , коэффициент дисконтирования γ , параметр λ

```
1:  $V[s] \leftarrow 0 \ \forall s \in S$ 
2: for всех эпизодов do
3:    $s \leftarrow$  начальное состояние
4:    $E[x] \leftarrow 0 \ \forall x \in S$ 
5:   for всех шагов эпизода do
6:      $a \sim \pi(\cdot \mid s)$ 
7:      $r, s' \leftarrow$  применение  $a$ 
8:      $\delta \leftarrow r + \gamma V[s'] - V[s]$ 
9:      $E[s] \leftarrow E[s] + 1$ 
10:    for всех нетерминальных состояний  $x \in S$  do
11:       $V[x] \leftarrow V[x] + \alpha \delta E[x]$ 
12:       $E[x] \leftarrow \gamma \lambda E[x]$ 
13:    end for
18:  end for
19: end for
```

▷ терминальные значения оставляем нулевыми

▷ прошлый эпизод не влияет на новый

▷ оцениваем фиксированную стратегию

▷ насколько уточнилась оценка отдачи

▷ увеличиваем вес посещённого состояния

▷ распределяем ошибку по весам

▷ давние посещения влияют слабее

Алгоритм TD(λ)

Смесь TD-обновлений и МК, контролируемая параметром λ . $\lambda = 0$ — TD, $\lambda = 1$ — МК.

Вход: среда $\langle S, A \rangle$, фиксированная стратегия π , шаг обучения α , коэффициент дисконтирования γ , параметр λ

```
1:  $V[s] \leftarrow 0 \ \forall s \in S$ 
2: for всех эпизодов do
3:    $s \leftarrow$  начальное состояние
4:    $E[x] \leftarrow 0 \ \forall x \in S$ 
5:   for всех шагов эпизода do
6:      $a \sim \pi(\cdot \mid s)$ 
7:      $r, s' \leftarrow$  применение  $a$ 
8:      $\delta \leftarrow r + \gamma V[s'] - V[s]$ 
9:      $E[s] \leftarrow E[s] + 1$ 
10:    for всех нетерминальных состояний  $x \in S$  do
11:       $V[x] \leftarrow V[x] + \alpha \delta E[x]$ 
12:       $E[x] \leftarrow \gamma \lambda E[x]$ 
13:    end for
14:    if  $s'$  терминальное then
15:      break
16:    end if
17:     $s \leftarrow s'$ 
18:  end for
19: end for
```

▷ терминальные значения оставляем нулевыми

▷ прошлый эпизод не влияет на новый

▷ оцениваем фиксированную стратегию

▷ насколько уточнилась оценка отдачи

▷ увеличиваем вес посещённого состояния



▷ распределяем ошибку по весам

▷ давние посещения влияют слабее

▷ ошибка последнего перехода уже учтена

Что дальше?

Нейросетевая аппроксимация



Вопросы?