

Нейросетевые методы аппроксимации функции полезности

Алексей Скрынник


ПЛАН

- 01 Q-обучение и память прецедентов
- 02 Нейросетевая аппроксимация
- 03 Обучение Q-сети
- 04 Алгоритм DQN
- 05 Улучшения DQN

01

Q-обучение и память прецедентов

Тестовые среды: видеоигры



Напоминание: Q-обучение

Уравнение оптимальности Беллмана для Q^* : для всех $s \in \mathcal{S}$, $a \in \mathcal{A}$

$$Q^*(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim p(\cdot | s, a)} \left[\max_{a' \in \mathcal{A}} Q^*(s', a') \right].$$

Напоминание: Q-обучение

Уравнение оптимальности Беллмана для Q^* : для всех $s \in \mathcal{S}$, $a \in \mathcal{A}$

$$Q^*(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim p(\cdot | s, a)} \left[\max_{a' \in \mathcal{A}} Q^*(s', a') \right].$$

Оптимальная стратегия:

$$a^*(s) \in \arg \max_{a \in \mathcal{A}} Q^*(s, a), \quad \pi^*(a^*(s) | s) = 1.$$

Напоминание: Q-обучение

Уравнение оптимальности Беллмана для Q^* : для всех $s \in \mathcal{S}$, $a \in \mathcal{A}$

$$Q^*(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim p(\cdot | s, a)} \left[\max_{a' \in \mathcal{A}} Q^*(s', a') \right].$$

Оптимальная стратегия:

$$a^*(s) \in \arg \max_{a \in \mathcal{A}} Q^*(s, a), \quad \pi^*(a^*(s) | s) = 1.$$

Q-обучение позволяет найти Q^* методом проб и ошибок в конечных МППР:

$$|\mathcal{S}| < \infty, \quad |\mathcal{A}| < \infty.$$

Напоминание: смысл обновления Q-обучения

Для перехода (s, a, r, s') :

$$Q_{k+1}(s, a) \leftarrow Q_k(s, a) + \alpha_k \underbrace{\left(\overbrace{r + \gamma \max_{a'} Q_k(s', a')}^{\text{показатель Q-обучения}} - Q_k(s, a) \right)}_{\text{TD-ошибка}}.$$

Напоминание: смысл обновления Q-обучения

Для перехода (s, a, r, s') :

$$Q_{k+1}(s, a) \leftarrow Q_k(s, a) + \alpha_k \underbrace{\left(\overbrace{r + \gamma \max_{a'} Q_k(s', a')}^{\text{показатель Q-обучения}} - Q_k(s, a) \right)}_{\text{TD-ошибка}}.$$

s, a — считаем фиксированными, их можно выбирать произвольно;

(!) Каждая пара должна обновляться бесконечно много раз.

Без новых обновлений ошибочная оценка может сохраниться.

Повторные обновления уменьшают влияние случайных наград и переходов.

Напоминание: смысл обновления Q-обучения

Для перехода (s, a, r, s') :

$$Q_{k+1}(s, a) \leftarrow Q_k(s, a) + \alpha_k \underbrace{\left(\overbrace{r + \gamma \max_{a'} Q_k(s', a')}^{\text{показатель Q-обучения}} - Q_k(s, a) \right)}_{\text{TD-ошибка}}.$$

s, a — считаем фиксированными, их можно выбирать произвольно;

(!) Каждая пара должна обновляться бесконечно много раз.

Без новых обновлений ошибочная оценка может сохраниться.


Повторные обновления уменьшают влияние случайных наград и переходов.

$s' \sim p(\cdot \mid s, a)$ — случайная величина из опыта взаимодействия.

Воспроизведение опыта (Experience Replay)

Сохраняем наблюдаемые переходы (s, a, r, s')
в **памяти прецедентов**!

**Память
прецедентов**




Воспроизведение опыта (Experience Replay)

Сохраняем наблюдаемые переходы (s, a, r, s')
в **памяти прецедентов**!

На каждом шаге **равновероятно** выбираем переход.
Используем его для обновления Q .

**Память
прецедентов**




Воспроизведение опыта (Experience Replay)

Сохраняем наблюдаемые переходы (s, a, r, s')
в **памяти прецедентов**!

На каждом шаге **равновероятно** выбираем переход.
Используем его для обновления Q .

✓ Повторно используем опыт.

**Память
прецедентов**




Воспроизведение опыта (Experience Replay)

Сохраняем наблюдаемые переходы (s, a, r, s')
в **памяти прецедентов**!

На каждом шаге **равновероятно** выбираем переход.
Используем его для обновления Q .

- ✓ Повторно используем опыт.
- ✓ Можем обучаться на данных эксперта.

**Память
прецедентов**




Воспроизведение опыта (Experience Replay)

Сохраняем наблюдаемые переходы (s, a, r, s')
в **памяти прецедентов**!

На каждом шаге **равновероятно** выбираем переход.
Используем его для обновления Q .

- ✓ Повторно используем опыт.
- ✓ Можем обучаться на данных эксперта.
- ✗ Следующее состояние берём из эмпирического распределения: $s' \sim \hat{p}(\cdot \mid s, a) \approx p(\cdot \mid s, a)$.

**Память
прецедентов**




Воспроизведение опыта (Experience Replay)

Сохраняем наблюдаемые переходы (s, a, r, s')
в **памяти прецедентов**!

На каждом шаге **равновероятно** выбираем переход.
Используем его для обновления Q .

- ✓ Повторно используем опыт.
- ✓ Можем обучаться на данных эксперта.
- ✗ Следующее состояние берём из эмпирического распределения: $s' \sim \hat{p}(\cdot \mid s, a) \approx p(\cdot \mid s, a)$.
- ✓ Больше данных помогает уменьшить ошибку выборки.

**Память
прецедентов**



Q-обучение с памятью прецедентов

Q-обучение (онлайн)

- 1: Инициализировать $Q[s, a]$ произвольно
- 2: $s_0 \leftarrow$ начальное состояние
- 3: **for** $k = 0, 1, 2, \dots$ **do**
- 4: $a_k \leftarrow \epsilon$ -жадный выбор по $Q[s_k, \cdot]$
- 5: $r_{k+1}, s_{k+1} \leftarrow$ применение a_k
- 8: **end for**

Q-обучение с памятью прецедентов

Q-обучение (онлайн)

- 1: Инициализировать $Q[s, a]$ произвольно
- 2: $s_0 \leftarrow$ начальное состояние
- 3: **for** $k = 0, 1, 2, \dots$ **do**
- 4: $a_k \leftarrow \epsilon$ -жадный выбор по $Q[s_k, \cdot]$
- 5: $r_{k+1}, s_{k+1} \leftarrow$ применение a_k
- 6: $y \leftarrow r_{k+1} + \gamma \max_{a'} Q[s_{k+1}, a']$
- 8: **end for**

Q-обучение с памятью прецедентов

Q-обучение (онлайн)

- 1: Инициализировать $Q[s, a]$ произвольно
- 2: $s_0 \leftarrow$ начальное состояние
- 3: **for** $k = 0, 1, 2, \dots$ **do**
- 4: $a_k \leftarrow \epsilon$ -жадный выбор по $Q[s_k, \cdot]$
- 5: $r_{k+1}, s_{k+1} \leftarrow$ применение a_k
- 6: $y \leftarrow r_{k+1} + \gamma \max_{a'} Q[s_{k+1}, a']$
- 7: $Q[s_k, a_k] \leftarrow (1 - \alpha_k)Q[s_k, a_k] + \alpha_k y$
- 8: **end for**

Q-обучение с памятью прецедентов

Q-обучение (онлайн)

- 1: Инициализировать $Q[s, a]$ произвольно
- 2: $s_0 \leftarrow$ начальное состояние
- 3: **for** $k = 0, 1, 2, \dots$ **do**
- 4: $a_k \leftarrow \epsilon$ -жадный выбор по $Q[s_k, \cdot]$
- 5: $r_{k+1}, s_{k+1} \leftarrow$ применение a_k
- 6: $y \leftarrow r_{k+1} + \gamma \max_{a'} Q[s_{k+1}, a']$
- 7: $Q[s_k, a_k] \leftarrow (1 - \alpha_k)Q[s_k, a_k] + \alpha_k y$
- 8: **end for**

Q-обучение с памятью прецедентов

- 1: Инициализировать $Q[s, a]$ произвольно
- 2: $\mathcal{D} \leftarrow \emptyset$

Q-обучение с памятью прецедентов

Q-обучение (онлайн)

- 1: Инициализировать $Q[s, a]$ произвольно
- 2: $s_0 \leftarrow$ начальное состояние
- 3: **for** $k = 0, 1, 2, \dots$ **do**
- 4: $a_k \leftarrow \epsilon$ -жадный выбор по $Q[s_k, \cdot]$
- 5: $r_{k+1}, s_{k+1} \leftarrow$ применение a_k
- 6: $y \leftarrow r_{k+1} + \gamma \max_{a'} Q[s_{k+1}, a']$
- 7: $Q[s_k, a_k] \leftarrow (1 - \alpha_k)Q[s_k, a_k] + \alpha_k y$
- 8: **end for**

Q-обучение с памятью прецедентов

- 1: Инициализировать $Q[s, a]$ произвольно
- 2: $\mathcal{D} \leftarrow \emptyset$
- 3: $s_0 \leftarrow$ начальное состояние
- 4: **for** $k = 0, 1, 2, \dots$ **do**
- 5: $a_k \leftarrow \epsilon$ -жадный выбор по $Q[s_k, \cdot]$
- 6: $r_{k+1}, s_{k+1} \leftarrow$ применение a_k
- 7: Сохранить $(s_k, a_k, r_{k+1}, s_{k+1})$ в $\mathcal{D}$
- 11: **end for**

Q-обучение с памятью прецедентов

Q-обучение (онлайн)

- 1: Инициализировать $Q[s, a]$ произвольно
- 2: $s_0 \leftarrow$ начальное состояние
- 3: **for** $k = 0, 1, 2, \dots$ **do**
- 4: $a_k \leftarrow \epsilon$ -жадный выбор по $Q[s_k, \cdot]$
- 5: $r_{k+1}, s_{k+1} \leftarrow$ применение a_k
- 6: $y \leftarrow r_{k+1} + \gamma \max_{a'} Q[s_{k+1}, a']$
- 7: $Q[s_k, a_k] \leftarrow (1 - \alpha_k)Q[s_k, a_k] + \alpha_k y$
- 8: **end for**

Q-обучение с памятью прецедентов


- 1: Инициализировать $Q[s, a]$ произвольно
- 2: $\mathcal{D} \leftarrow \emptyset$
- 3: $s_0 \leftarrow$ начальное состояние
- 4: **for** $k = 0, 1, 2, \dots$ **do**
- 5: $a_k \leftarrow \epsilon$ -жадный выбор по $Q[s_k, \cdot]$
- 6: $r_{k+1}, s_{k+1} \leftarrow$ применение a_k
- 7: Сохранить $(s_k, a_k, r_{k+1}, s_{k+1})$ в $\mathcal{D}$
- 8: $(s, a, r, s') \sim \text{Uniform}(\mathcal{D})$
- 9: $y \leftarrow r + \gamma \max_{a'} Q[s', a']$
- 10: $Q[s, a] \leftarrow (1 - \alpha_k)Q[s, a] + \alpha_k y$
- 11: **end for**

02

Нейросетевая аппроксимация

Игры Atari


Предположение: $|\mathcal{S}| \ll \infty, |\mathcal{A}| \ll \infty$.



Игры Atari

Предположение: ~~$|\mathcal{S}| \ll \infty$~~ , $|\mathcal{A}| \ll \infty$.


- 57 различных игр.
- Наблюдение — кадр экрана.
- Без специальных признаков для игры.
- Конечное, но огромное $|\mathcal{S}|$.
- $|\mathcal{A}| \leq 18$.



Игры Atari

Предположение: ~~$|\mathcal{S}| \ll \infty$~~ , $|\mathcal{A}| \ll \infty$.

- 57 различных игр.
- Наблюдение — кадр экрана.
- Без специальных признаков для игры.
- Конечное, но огромное $|\mathcal{S}|$.
- $|\mathcal{A}| \leq 18$.



Аппроксимируем $Q^*(s, a)$ нейронной сетью!

Достаточно ли одного кадра для выбора действия?



Практические замечания: предобработка

Кадры и выбор действий

- FrameStack.
- FrameSkip.
- MaxAndSkip.
- Иногда — Sticky Actions.

Предобработка для Atari

- EpisodicLife.
- FireReset.

Обработка изображения


- Обрезка изображения.
- Изменение размера (обычно 84×84).
- Перевод в оттенки серого.

Обработка вознаграждения


(!) Приводим награду к $\{-1, 0, 1\}$.

Глубокая Q-сеть

Вариант 1




Вариант 2




Глубокая Q-сеть

Вариант 1



✗ $\arg \max_a Q_\phi(s, a)$ — дорого!

Вариант 2



✓ $\arg \max_a Q_\phi(s, a)$ — один проход сети.

Глубокая Q-сеть: архитектура

- 3–4 свёрточных слоя, затем 1–2 полносвязных слоя.
- Шаг свёртки > 1 уменьшает размер. Полносвязные слои — широкие.

Использовать с осторожностью

- ✗ Max pooling.
- ✗ Batch normalization.
- ✗ Dropout.



03

Обучение Q-сети

Как обучать Q-сеть?

Обучение с учителем

- Входы x и готовые ответы y .
- Модель $\hat{y}_\phi(x)$.
- Функция потерь $\mathcal{L}(y, \hat{y})$.

Как обучать Q-сеть?

Обучение с учителем

- Входы x и готовые ответы y .
- Модель $\hat{y}_\phi(x)$.
- Функция потерь $\mathcal{L}(y, \hat{y})$.

Подбираем параметры модели:

$$\sum_{(x,y)} \mathcal{L}(y, \hat{y}_\phi(x)) \longrightarrow \min_{\phi}.$$

Используем стохастический градиентный спуск.

Как обучать Q-сеть?

Обучение с учителем

- Входы x и готовые ответы y .
- Модель $\hat{y}_\phi(x)$.
- Функция потерь $\mathcal{L}(y, \hat{y})$.

Подбираем параметры модели:

$$\sum_{(x,y)} \mathcal{L}(y, \hat{y}_\phi(x)) \longrightarrow \min_{\phi}.$$

Используем стохастический градиентный спуск.

Обучение Q-сети

- Переходы (s, a, r, s') собираем сами.
- Данные зависят от стратегии и коррелированы.

Как обучать Q-сеть?

Обучение с учителем

- Входы x и готовые ответы y .
- Модель $\hat{y}_\phi(x)$.
- Функция потерь $\mathcal{L}(y, \hat{y})$.

Подбираем параметры модели:

$$\sum_{(x,y)} \mathcal{L}(y, \hat{y}_\phi(x)) \longrightarrow \min_{\phi}.$$

Используем стохастический градиентный спуск.

Обучение Q-сети

- Переходы (s, a, r, s') собираем сами.
- Данные зависят от стратегии и коррелированы.
- Готовых значений $Q^*(s, a)$ нет.

Как обучать Q-сеть?

Обучение с учителем

- Входы x и готовые ответы y .
- Модель $\hat{y}_\phi(x)$.
- Функция потерь $\mathcal{L}(y, \hat{y})$.

Подбираем параметры модели:

$$\sum_{(x,y)} \mathcal{L}(y, \hat{y}_\phi(x)) \longrightarrow \min_{\phi}.$$

Используем стохастический градиентный спуск.

Обучение Q-сети

- Переходы (s, a, r, s') собираем сами.
- Данные зависят от стратегии и коррелированы.
- Готовых значений $Q^*(s, a)$ нет.

Как построить обучающий ответ для $Q_\phi(s, a)$?

Q-обучение как градиентный шаг

Для перехода (s, a, r, s') с нетерминальным s' : $\hat{y} = Q_{\phi}(s, a)$.

Q-обучение как градиентный шаг

Для перехода (s, a, r, s') с нетерминальным s' : $\hat{y} = Q_\phi(s, a)$.

Строим показатель Q-обучения по текущей оценке:

$$y \leftarrow r + \gamma \max_{a'} Q_\phi(s', a').$$

При вычислении градиента считаем y константой.

Q-обучение как градиентный шаг

Для перехода (s, a, r, s') с нетерминальным s' : $\hat{y} = Q_\phi(s, a)$.

Строим показатель Q-обучения по текущей оценке:

$$y \leftarrow r + \gamma \max_{a'} Q_\phi(s', a').$$

При вычислении градиента считаем y константой.

MSE: средний квадрат ошибки (здесь — один переход и множитель $\frac{1}{2}$).

$$\mathcal{L}(\phi) = \frac{1}{2} (y - Q_\phi(s, a))^2, \quad \nabla_\phi \mathcal{L} = -(y - Q_\phi(s, a)) \nabla_\phi Q_\phi(s, a).$$

Q-обучение как градиентный шаг

Для перехода (s, a, r, s') с нетерминальным s' : $\hat{y} = Q_\phi(s, a)$.

Строим показатель Q-обучения по текущей оценке:

$$y \leftarrow r + \gamma \max_{a'} Q_\phi(s', a').$$

При вычислении градиента считаем y константой.

MSE: средний квадрат ошибки (здесь — один переход и множитель $\frac{1}{2}$).

$$\mathcal{L}(\phi) = \frac{1}{2} (y - Q_\phi(s, a))^2, \quad \nabla_\phi \mathcal{L} = -(y - Q_\phi(s, a)) \nabla_\phi Q_\phi(s, a).$$

Градиентный шаг:

$$\phi \leftarrow \phi - \alpha \nabla_\phi \mathcal{L} = \phi + \alpha (y - Q_\phi(s, a)) \nabla_\phi Q_\phi(s, a).$$

Q-обучение как градиентный шаг

Для перехода (s, a, r, s') с нетерминальным s' : $\hat{y} = Q_\phi(s, a)$.

Строим показатель Q-обучения по текущей оценке:

$$y \leftarrow r + \gamma \max_{a'} Q_\phi(s', a').$$

При вычислении градиента считаем y константой.

MSE: средний квадрат ошибки (здесь — один переход и множитель $\frac{1}{2}$).

$$\mathcal{L}(\phi) = \frac{1}{2}(y - Q_\phi(s, a))^2, \quad \nabla_\phi \mathcal{L} = -(y - Q_\phi(s, a)) \nabla_\phi Q_\phi(s, a).$$

Градиентный шаг:

$$\phi \leftarrow \phi - \alpha \nabla_\phi \mathcal{L} = \phi + \alpha (y - Q_\phi(s, a)) \nabla_\phi Q_\phi(s, a).$$


Для таблицы $Q_\phi(s, a) = \phi_{s,a}$ получаем обычное Q-обновление:

$$\phi_{s,a} \leftarrow \phi_{s,a} + \alpha (y - \phi_{s,a}).$$

Stop-gradient: фиксируем обучающий ответ

Показатель Q-обучения — ответ, к которому приближаем текущую оценку.


Например, текущая оценка равна 0, а вычисленный ответ — 10.



Stop-gradient: фиксируем обучающий ответ

Показатель Q-обучения — ответ, к которому приближаем текущую оценку.

Например, текущая оценка равна 0, а вычисленный ответ — 10.



Stop-gradient: вычисляем y и считаем его константой при вычислении градиента на этом шаге.

Что будет, если обучать и сам ответ?

В примере с независимыми оценками:

- Текущую оценку повышаем.
- Оценку, из которой построен ответ, снижаем.



Что будет, если обучать и сам ответ?

В примере с независимыми оценками:

- Текущую оценку повышаем.
- Оценку, из которой построен ответ, снижаем.

Ошибка уменьшается и за счёт того, что мы меняем сам ориентир.

Как погоня за собственным хвостом.



Глубокое Q-обучение

Рассмотрим задачу регрессии:

- Вход — состояние s и действие a .
- Обучающий ответ $y_k \in \mathbb{R}$ для нетерминального s' :

$$y_k = r + \gamma \max_{a'} Q_{\phi_k}(s', a'),$$

где (s, a, r, s') — наблюдаемый переход.

Глубокое Q-обучение

Рассмотрим задачу регрессии:

- Вход — состояние s и действие a .
- Обучающий ответ $y_k \in \mathbb{R}$ для нетерминального s' :

$$y_k = r + \gamma \max_{a'} Q_{\phi_k}(s', a'),$$

где (s, a, r, s') — наблюдаемый переход.

- Функция потерь — MSE: $\mathcal{L}(y_k, \hat{y}) = \frac{1}{2}(y_k - \hat{y})^2$.

Глубокое Q-обучение

Рассмотрим задачу регрессии:

- Вход — состояние s и действие a .
- Обучающий ответ $y_k \in \mathbb{R}$ для нетерминального s' :

$$y_k = r + \gamma \max_{a'} Q_{\phi_k}(s', a'),$$

где (s, a, r, s') — наблюдаемый переход.

- Функция потерь — MSE: $\mathcal{L}(y_k, \hat{y}) = \frac{1}{2}(y_k - \hat{y})^2$.

$$\mathbb{E}_{(s,a,r,s')} \left[\frac{1}{2} (y_k - Q_{\phi_{k+1}}(s, a))^2 \right] \longrightarrow \min_{\phi_{k+1}}.$$

Решение уравнения Беллмана нейросетью

$$\mathbb{E}_{(s,a,r,s')} \left[\frac{1}{2} (y_k - Q_{\phi_{k+1}}(s, a))^2 \right] \longrightarrow \min_{\phi_{k+1}}.$$

Какое решение оптимально?

Если модель может точно представить условное среднее.

$$Q_{\phi_{k+1}^*}(s, a) =$$

Решение уравнения Беллмана нейросетью

$$\mathbb{E}_{(s,a,r,s')} \left[\frac{1}{2} (y_k - Q_{\phi_{k+1}}(s, a))^2 \right] \longrightarrow \min_{\phi_{k+1}}.$$

Какое решение оптимально?

Если модель может точно представить условное среднее.

$$Q_{\phi_{k+1}^*}(s, a) = \mathbb{E}_{r,s'|s,a}[y_k]$$

Решение уравнения Беллмана нейросетью

$$\mathbb{E}_{(s,a,r,s')} \left[\frac{1}{2} (y_k - Q_{\phi_{k+1}}(s, a))^2 \right] \longrightarrow \min_{\phi_{k+1}}.$$

Какое решение оптимально?

Если модель может точно представить условное среднее.

$$\begin{aligned} Q_{\phi_{k+1}^*}(s, a) &= \mathbb{E}_{r,s'|s,a}[y_k] \\ &= \mathbb{E}_{r,s'|s,a} \left[r + \gamma \max_{a'} Q_{\phi_k}(s', a') \right] \end{aligned}$$

Решение уравнения Беллмана нейросетью

$$\mathbb{E}_{(s,a,r,s')} \left[\frac{1}{2} (y_k - Q_{\phi_{k+1}}(s, a))^2 \right] \longrightarrow \min_{\phi_{k+1}}.$$

Какое решение оптимально?

Если модель может точно представить условное среднее.

$$\begin{aligned} Q_{\phi_{k+1}^*}(s, a) &= \mathbb{E}_{r,s'|s,a}[y_k] \\ &= \mathbb{E}_{r,s'|s,a} \left[r + \gamma \max_{a'} Q_{\phi_k}(s', a') \right] \\ &= \underbrace{r(s, a) + \gamma \mathbb{E}_{s' \sim p(\cdot|s,a)} \left[\max_{a'} Q_{\phi_k}(s', a') \right]}_{\text{обновление итерации по полезностям}}. \end{aligned}$$

04

Алгоритм DQN

Целевая сеть: замораживаем копию



Обновили сеть — изменились и ответы,
по которым её обучаем.

Целевая сеть: замораживаем копию



Обновили сеть — изменились и ответы, по которым её обучаем.

Используем две сети:

- Основная сеть Q_ϕ — обучается.
- Копия $Q_{\bar{\phi}}$ — вычисляет ответы. Её веса пока не меняем.

Для одного и того же перехода ответ остаётся прежним.

Целевая сеть: замораживаем копию



Обновили сеть — изменились и ответы, по которым её обучаем.

Используем две сети:


- Основная сеть Q_ϕ — обучается.
- Копия $Q_{\bar{\phi}}$ — вычисляет ответы. Её веса пока не меняем.

Для одного и того же перехода ответ остаётся прежним.


После K обновлений основной сети копируем её веса в целевую:

$$\bar{\phi} \leftarrow \phi.$$

Последовательные наблюдения коррелированы



Воспроизведение опыта



Нужно ли продолжать эпизод?

Пробы и ошибки



Нужно ли продолжать эпизод?

Пробы и ошибки




Нужно ли продолжать эпизод?

Пробы и ошибки



Локальный оптимум



Нужно ли продолжать эпизод?


Пробы и ошибки



Локальный оптимум



Память
прецедентов



Эпизод закончился: задача завершена или прервана?

Termination: задача завершена

Достигнуто терминальное состояние.
Например, агент достиг цели или проиграл.

Продолжения по правилам задачи нет.

$$y = r.$$

Эпизод закончился: задача завершена или прервана?

Termination: задача завершена

Достигнуто терминальное состояние.
Например, агент достиг цели или проиграл.

Продолжения по правилам задачи нет.

$$y = r.$$

Truncation: сбор опыта прерван

Сработал внешний лимит шагов.
Сама задача могла бы продолжаться.

Учитываем оценку продолжения:

$$y = r + \gamma \max_{a'} Q_{\bar{\phi}}(s', a').$$

Эпизод закончился: задача завершена или прервана?

Termination: задача завершена

Достигнуто терминальное состояние.
Например, агент достиг цели или проиграл.

Продолжения по правилам задачи нет.

$$y = r.$$

Truncation: сбор опыта прерван

Сработал внешний лимит шагов.
Сама задача могла бы продолжаться.

Учитываем оценку продолжения:

$$y = r + \gamma \max_{a'} Q_{\bar{\phi}}(s', a').$$

Конец сбора опыта не всегда означает конец будущих наград.

Если срок задан правилами самой задачи, его истечение — termination.
Оставшееся время должно входить в состояние, доступное агенту.

Два флага — два разных решения

$d_{\text{term}} = \text{terminated}, d_{\text{trunc}} = \text{truncated}.$

Когда начинать новый эпизод?

$$d_{\text{term}} \vee d_{\text{trunc}} \longrightarrow \text{reset()}.$$

Два флага — два разных решения

$d_{\text{term}} = \text{terminated}, d_{\text{trunc}} = \text{truncated}.$

Когда начинать новый эпизод?

$$d_{\text{term}} \vee d_{\text{trunc}} \longrightarrow \text{reset()}.$$

Когда учитывать будущую награду?

$$y = r + \gamma(1 - d_{\text{term}}) \max_{a'} Q_{\bar{\phi}}(s', a').$$

При внешнем лимите шагов бутстреп сохраняем.

Два флага — два разных решения

$d_{\text{term}} = \text{terminated}, d_{\text{trunc}} = \text{truncated}.$

Когда начинать новый эпизод?

$$d_{\text{term}} \vee d_{\text{trunc}} \longrightarrow \text{reset()}.$$

Когда учитывать будущую награду?

$$y = r + \gamma(1 - d_{\text{term}}) \max_{a'} Q_{\bar{\phi}}(s', a').$$

При внешнем лимите шагов бутстреп сохраняем.

$$d_{\text{term}} = 1 \longrightarrow y = r,$$

$$d_{\text{term}} = 0, d_{\text{trunc}} = 1 \longrightarrow y = r + \gamma \max_{a'} Q_{\bar{\phi}}(s', a').$$

DQN: псевдокод

Вход: γ , ϵ , шаг обучения α , размер пакета B , период копирования K

1: Инициализировать параметры ϕ сети Q_ϕ

2: $\bar{\phi} \leftarrow \phi$, $\mathcal{D} \leftarrow \emptyset$

DQN: псевдокод

Вход: γ , ϵ , шаг обучения α , размер пакета B , период копирования K

1: Инициализировать параметры ϕ сети Q_ϕ

2: $\bar{\phi} \leftarrow \phi$, $\mathcal{D} \leftarrow \emptyset$

3: $s \leftarrow \text{reset}()$

4: **for** $k = 0, 1, 2, \dots$ **do**

5: $a \leftarrow \epsilon$ -жадный выбор по $Q_\phi(s, \cdot)$

6: $r, s', d_{\text{term}}, d_{\text{trunc}} \leftarrow$ применение a

7: Сохранить $(s, a, r, s', d_{\text{term}})$ в $\mathcal{D}$

▷ s' до сброса среды

15: Если $d_{\text{term}} \vee d_{\text{trunc}}$: $s \leftarrow \text{reset}()$; иначе $s \leftarrow s'$

16: **end for**

DQN: псевдокод

Вход: γ , ϵ , шаг обучения α , размер пакета B , период копирования K

1: Инициализировать параметры ϕ сети Q_ϕ

2: $\bar{\phi} \leftarrow \phi$, $\mathcal{D} \leftarrow \emptyset$

3: $s \leftarrow \text{reset}()$

4: **for** $k = 0, 1, 2, \dots$ **do**

5: $a \leftarrow \epsilon$ -жадный выбор по $Q_\phi(s, \cdot)$

6: $r, s', d_{\text{term}}, d_{\text{trunc}} \leftarrow$ применение a

7: Сохранить $(s, a, r, s', d_{\text{term}})$ в $\mathcal{D}$

▷ s' до сброса среды

8: Выбрать B переходов $(s_i, a_i, r_i, s'_i, d_{\text{term},i})$ из $\mathcal{D}$ равновероятно с возвращением

15: Если $d_{\text{term}} \vee d_{\text{trunc}}$: $s \leftarrow \text{reset}()$; иначе $s \leftarrow s'$

16: **end for**

DQN: псевдокод

Вход: γ , ϵ , шаг обучения α , размер пакета B , период копирования K

1: Инициализировать параметры ϕ сети Q_ϕ

2: $\bar{\phi} \leftarrow \phi$, $\mathcal{D} \leftarrow \emptyset$

3: $s \leftarrow \text{reset}()$

4: **for** $k = 0, 1, 2, \dots$ **do**

5: $a \leftarrow \epsilon$ -жадный выбор по $Q_\phi(s, \cdot)$

6: $r, s', d_{\text{term}}, d_{\text{trunc}} \leftarrow$ применение a

7: Сохранить $(s, a, r, s', d_{\text{term}})$ в $\mathcal{D}$

▷ s' до сброса среды

8: Выбрать B переходов $(s_i, a_i, r_i, s'_i, d_{\text{term},i})$ из $\mathcal{D}$ равновероятно с возвращением

9: $y_i \leftarrow r_i + \gamma(1 - d_{\text{term},i}) \max_{a'} Q_{\bar{\phi}}(s'_i, a')$, $i = 1, \dots, B$

15: Если $d_{\text{term}} \vee d_{\text{trunc}}$: $s \leftarrow \text{reset}()$; иначе $s \leftarrow s'$

16: **end for**

DQN: псевдокод

Вход: γ , ϵ , шаг обучения α , размер пакета B , период копирования K

```
1: Инициализировать параметры  $\phi$  сети  $Q_\phi$ 
2:  $\bar{\phi} \leftarrow \phi$ ,  $\mathcal{D} \leftarrow \emptyset$ 
3:  $s \leftarrow \text{reset}()$ 
4: for  $k = 0, 1, 2, \dots$  do
5:    $a \leftarrow \epsilon$ -жадный выбор по  $Q_\phi(s, \cdot)$ 
6:    $r, s', d_{\text{term}}, d_{\text{trunc}} \leftarrow$  применение  $a$ 
7:   Сохранить  $(s, a, r, s', d_{\text{term}})$  в  $\mathcal{D}$  ▷  $s'$  до сброса среды
8:   Выбрать  $B$  переходов  $(s_i, a_i, r_i, s'_i, d_{\text{term},i})$  из  $\mathcal{D}$  равновероятно с возвращением
9:    $y_i \leftarrow r_i + \gamma(1 - d_{\text{term},i}) \max_{a'} Q_{\bar{\phi}}(s'_i, a')$ ,  $i = 1, \dots, B$ 
10:   $\mathcal{L}(\phi) \leftarrow \frac{1}{2B} \sum_{i=1}^B (Q_\phi(s_i, a_i) - y_i)^2$ 
11:   $\phi \leftarrow \phi - \alpha \nabla_\phi \mathcal{L}(\phi)$  ▷  $y_i$  фиксированы

15:   Если  $d_{\text{term}} \vee d_{\text{trunc}}$ :  $s \leftarrow \text{reset}()$ ; иначе  $s \leftarrow s'$ 
16: end for
```

DQN: псевдокод


Вход: γ , ϵ , шаг обучения α , размер пакета B , период копирования K

```
1: Инициализировать параметры  $\phi$  сети  $Q_\phi$ 
2:  $\bar{\phi} \leftarrow \phi$ ,  $\mathcal{D} \leftarrow \emptyset$ 
3:  $s \leftarrow \text{reset}()$ 
4: for  $k = 0, 1, 2, \dots$  do
5:    $a \leftarrow \epsilon$ -жадный выбор по  $Q_\phi(s, \cdot)$ 
6:    $r, s', d_{\text{term}}, d_{\text{trunc}} \leftarrow$  применение  $a$ 
7:   Сохранить  $(s, a, r, s', d_{\text{term}})$  в  $\mathcal{D}$  ▷  $s'$  до сброса среды
8:   Выбрать  $B$  переходов  $(s_i, a_i, r_i, s'_i, d_{\text{term},i})$  из  $\mathcal{D}$  равновероятно с возвращением
9:    $y_i \leftarrow r_i + \gamma(1 - d_{\text{term},i}) \max_{a'} Q_{\bar{\phi}}(s'_i, a')$ ,  $i = 1, \dots, B$ 
10:   $\mathcal{L}(\phi) \leftarrow \frac{1}{2B} \sum_{i=1}^B (Q_\phi(s_i, a_i) - y_i)^2$ 
11:   $\phi \leftarrow \phi - \alpha \nabla_\phi \mathcal{L}(\phi)$  ▷  $y_i$  фиксированы
12:  if  $(k + 1) \bmod K = 0$  then
13:     $\bar{\phi} \leftarrow \phi$  ▷ обновить целевую сеть
14:  end if
15:  Если  $d_{\text{term}} \vee d_{\text{trunc}}$ :  $s \leftarrow \text{reset}()$ ; иначе  $s \leftarrow s'$ 
16: end for
```


05

Улучшения DQN

Есть что улучшить



DQN




Double
DQN




Multistep
DQN




Prioritized
Replay



Noisy
Nets




Categorical
DQN



Dueling
DQN

Rainbow: вклад каждого улучшения

- Убираем по одному компоненту и смотрим, как меняется результат.
- Особенно заметно падение без многошагового обучения и приоритетной памяти прецедентов.



Double DQN

Завышение оценок: как с ним бороться?

$$Q_{\phi}(s', a') = Q^*(s', a') + \underbrace{\xi(s', a')}_{\text{ошибка оценки}}, \quad \mathbb{E}_{\xi}[\xi(s', a')] = 0.$$

Завышение оценок: как с ним бороться?

$$Q_\phi(s', a') = Q^*(s', a') + \underbrace{\xi(s', a')}_{\text{ошибка оценки}}, \quad \mathbb{E}_\xi[\xi(s', a')] = 0.$$

$$\mathbb{E}_\xi \left[\max_{a'} (Q^*(s', a') + \xi(s', a')) \right] \geq \max_{a'} Q^*(s', a').$$

Завышение оценок: как с ним бороться?

$$Q_\phi(s', a') = Q^*(s', a') + \underbrace{\xi(s', a')}_{\text{ошибка оценки}}, \quad \mathbb{E}_\xi[\xi(s', a')] = 0.$$

$$\mathbb{E}_\xi \left[\max_{a'} (Q^*(s', a') + \xi(s', a')) \right] \geq \max_{a'} Q^*(s', a').$$

Разделим **выбор действия** и **оценку действия**:

$$\max_{a'} Q_\phi(s', a') = \overbrace{Q_\phi \left(s', \underbrace{\arg \max_{a'} Q_\phi(s', a')}_{\text{выбор действия}} \right)}^{\text{оценка действия}}.$$

Завышение оценок: как с ним бороться?

$$Q_\phi(s', a') = Q^*(s', a') + \underbrace{\xi(s', a')}_{\text{ошибка оценки}}, \quad \mathbb{E}_\xi[\xi(s', a')] = 0.$$

$$\mathbb{E}_\xi \left[\max_{a'} (Q^*(s', a') + \xi(s', a')) \right] \geq \max_{a'} Q^*(s', a').$$

Разделим **выбор действия** и **оценку действия**:

$$\max_{a'} Q_\phi(s', a') = \overbrace{Q_\phi \left(s', \underbrace{\arg \max_{a'} Q_\phi(s', a')}_{\text{выбор действия}} \right)}^{\text{оценка действия}}.$$

Выбираем действие одной сетью, оцениваем другой:

$$a^* = \arg \max_{a'} Q_\phi(s', a'), \quad Q_{\bar{\phi}}(s', a^*).$$

От DQN к Double DQN

Q_ϕ — обучаемая сеть, $Q_{\bar{\phi}}$ — целевая сеть.

Для нетерминального перехода ($d_{\text{term}} = 0$).

DQN: целевая сеть и выбирает, и оценивает.

$$y = r + \gamma \underbrace{Q_{\bar{\phi}}\left(s', \arg \max_{a'} Q_{\bar{\phi}}(s', a')\right)}_{\text{выбор действия}}.$$

От DQN к Double DQN

Q_ϕ — обучаемая сеть, $Q_{\bar{\phi}}$ — целевая сеть.

Для нетерминального перехода ($d_{\text{term}} = 0$).

DQN: целевая сеть и выбирает, и оценивает.

$$y = r + \gamma Q_{\bar{\phi}} \left(s', \underbrace{\arg \max_{a'} Q_{\bar{\phi}}(s', a')}_{\text{выбор действия}} \right).$$

Double DQN: обучаемая выбирает, целевая оценивает.

$$y = r + \gamma Q_{\bar{\phi}} \left(s', \underbrace{\arg \max_{a'} Q_\phi(s', a')}_{\text{выбор действия}} \right).$$

От DQN к Double DQN

Q_ϕ — обучаемая сеть, $Q_{\bar{\phi}}$ — целевая сеть.

Для нетерминального перехода ($d_{\text{term}} = 0$).

DQN: целевая сеть и выбирает, и оценивает.

$$y = r + \gamma Q_{\bar{\phi}} \left(s', \underbrace{\arg \max_{a'} Q_{\bar{\phi}}(s', a')}_{\text{выбор действия}} \right).$$

Double DQN: обучаемая выбирает, целевая оценивает.

$$y = r + \gamma Q_{\bar{\phi}} \left(s', \underbrace{\arg \max_{a'} Q_\phi(s', a')}_{\text{выбор действия}} \right).$$

➤ Меняем только сеть, которая выбирает следующее действие.

Две оценки: перекрёстная оценка или минимум?

Для нетерминального перехода ($d_{\text{term}} = 0$).

Double Q-learning: одна сеть выбирает, другая оценивает.

$$y_1 = r + \gamma Q_{\phi_2} \left(s', \arg \max_{a'} Q_{\phi_1}(s', a') \right).$$

Две оценки: перекрёстная оценка или минимум?

Для нетерминального перехода ($d_{\text{term}} = 0$).

Double Q-learning: одна сеть выбирает, другая оценивает.

$$y_1 = r + \gamma Q_{\phi_2} \left(s', \arg \max_{a'} Q_{\phi_1}(s', a') \right).$$

$$y_2 = r + \gamma Q_{\phi_1} \left(s', \arg \max_{a'} Q_{\phi_2}(s', a') \right).$$

На каждом шаге обновляем одну из двух сетей.

Две оценки: перекрёстная оценка или минимум?

Для нетерминального перехода ($d_{\text{term}} = 0$).

Double Q-learning: одна сеть выбирает, другая оценивает.

$$y_1 = r + \gamma Q_{\phi_2} \left(s', \arg \max_{a'} Q_{\phi_1}(s', a') \right).$$

$$y_2 = r + \gamma Q_{\phi_1} \left(s', \arg \max_{a'} Q_{\phi_2}(s', a') \right).$$

На каждом шаге обновляем одну из двух сетей.

Минимум: для выбранного действия берём меньшую оценку.


$$a_j^* = \arg \max_{a'} Q_{\phi_j}(s', a'), \quad y_j = r + \gamma \min \left(Q_{\phi_1}(s', a_j^*), Q_{\phi_2}(s', a_j^*) \right), \quad j \in \{1, 2\}.$$

Приоритетная память прецедентов

Какие переходы повторять чаще?

- Обычная память: все переходы выбираем с одинаковой вероятностью.


Память прецедентов



Какие переходы повторять чаще?

- Обычная память: все переходы выбираем с одинаковой вероятностью.
- На некоторых переходах сеть ошибается сильнее — у них больше TD-ошибка.

Память прецедентов



Какие переходы повторять чаще?

- Обычная память: все переходы выбираем с одинаковой вероятностью.
- На некоторых переходах сеть ошибается сильнее — у них больше TD-ошибка.
- Приоритетная память: такие переходы выбираем чаще.


$$P(i) \propto (|\delta_i| + \varepsilon_p)^\eta, \quad \delta_i = y_i - Q_\phi(s_i, a_i).$$

$\varepsilon_p > 0$ сохраняет шанс выбора каждого перехода;

$\eta \geq 0$ задаёт силу приоритета ($\eta = 0$ — равномерный выбор).

Повторяем чаще то, что пока плохо выучили.

Память прецедентов



Вопросы?