

Методы оптимизации градиента стратегии

Алексей Скрынник

ПЛАН

- 01 Прямой поиск стратегии
- 02 Вывод градиента стратегии
- 03 Уменьшение дисперсии
- 04 Актер-критик

01

Прямой поиск стратегии

Прямой поиск стратегии в RL

- Ранее мы использовали аппроксимацию функции полезности:

$$V_\phi(s) \approx V^\pi(s), \quad Q_\phi(s, a) \approx Q^\pi(s, a)$$


- Стратегия генерировалась напрямую по функции полезности (например, ϵ -жадно)
- Однако, можно напрямую параметризовать стратегию:

$$\pi_\theta(a|s) = \mathbb{P}[a|s, \theta]$$


- Вапник (1998) – не нужно решать общую задачу через промежуточные шаги

Типология методов RL

- Основанные на полезности (value-based):
 - легко интерпретируемы,
 - могут концентрироваться на не самых важных признаках
- Поиск стратегии (policy-based):
 - цель поиска – сама стратегия,
 - игнорируются другие полезные данные
- Актор-критик (actor-critic)
 - строят как функцию полезности,
 - так и стратегию



Неградиентные методы: экзоскелет



- Задача: подобрать параметры экзоскелета для снижения метаболических затрат при ходьбе
- Оптимизация методом CMA-ES — эволюционным алгоритмом, не требующим градиента целевой функции

Неградиентные методы: эволюционные стратегии

- Стратегия — чёрный ящик: не нужно знать, как она устроена внутри
- Пробуем случайные возмущения параметров, сдвигаем θ в сторону тех, что дали большую отдачу
- ES конкурирует с Актор-Критик подходами (A2C, A3C) на играх Atari, масштабируясь линейно с числом процессоров

Вход: шаг обучения α , std. откл. шума σ , начальные параметры θ_0

1: **for** $t = 0, 1, 2, \dots$ **do**

8: **end for**

Неградиентные методы: эволюционные стратегии

- Стратегия — чёрный ящик: не нужно знать, как она устроена внутри
- Пробуем случайные возмущения параметров, сдвигаем θ в сторону тех, что дали большую отдачу
- ES конкурирует с Актор-Критик подходами (A2C, A3C) на играх Atari, масштабируясь линейно с числом процессоров

Вход: шаг обучения α , std. откл. шума σ , начальные параметры θ_0

```
1: for  $t = 0, 1, 2, \dots$  do  
2:   сэмплируем  $\epsilon_1, \dots, \epsilon_n \sim \mathcal{N}(0, I)$ 
```

```
8: end for
```

Неградиентные методы: эволюционные стратегии

- Стратегия — чёрный ящик: не нужно знать, как она устроена внутри
- Пробуем случайные возмущения параметров, сдвигаем θ в сторону тех, что дали большую отдачу
- ES конкурирует с Актор-Критик подходами (A2C, A3C) на играх Atari, масштабируясь линейно с числом процессоров

Вход: шаг обучения α , std. откл. шума σ , начальные параметры θ_0

```
1: for  $t = 0, 1, 2, \dots$  do  
2:   сэмплируем  $\epsilon_1, \dots, \epsilon_n \sim \mathcal{N}(0, I)$   
3:   for  $i = 1, \dots, n$  do ▷ параллельно  
4:     запускаем  $\pi$  с параметрами  $\theta_t + \sigma \epsilon_i$   
5:     получаем отдачу  $G_i$   
6:   end for  
  
8: end for
```

Неградиентные методы: эволюционные стратегии

- Стратегия — чёрный ящик: не нужно знать, как она устроена внутри
- Пробуем случайные возмущения параметров, сдвигаем θ в сторону тех, что дали большую отдачу
- ES конкурирует с Актор-Критик подходами (A2C, A3C) на играх Atari, масштабируясь линейно с числом процессоров

Вход: шаг обучения α , std. откл. шума σ , начальные параметры θ_0

```
1: for  $t = 0, 1, 2, \dots$  do
2:   сэмплируем  $\epsilon_1, \dots, \epsilon_n \sim \mathcal{N}(0, I)$ 
3:   for  $i = 1, \dots, n$  do ▷ параллельно
4:     запускаем  $\pi$  с параметрами  $\theta_t + \sigma \epsilon_i$ 
5:     получаем отдачу  $G_i$ 
6:   end for
7:    $\theta_{t+1} \leftarrow \theta_t + \alpha \frac{1}{n\sigma} \sum_{i=1}^n G_i \epsilon_i$ 
8: end for
```

Преимущества RL методов, основанных на стратегии

Плюсы:

- Более гладкая и предсказуемая сходимость по сравнению с value-based методами
- Эффективны в задачах большой размерности и непрерывных пространствах действий
- Могут обучаться стохастическим стратегиям
- Иногда выучить стратегию проще, чем функцию полезности

Преимущества RL методов, основанных на стратегии

Плюсы:


- Более гладкая и предсказуемая сходимость по сравнению с value-based методами
- Эффективны в задачах большой размерности и непрерывных пространствах действий
- Могут обучаться стохастическим стратегиям
- Иногда выучить стратегию проще, чем функцию полезности

Минусы:

- Нет гарантий глобальной оптимальности (для нелинейных аппроксиматоров)
- Требуют больше данных (sample inefficiency)
- Высокая дисперсия оценок градиента


Клеточный мир с одинаковыми наблюдениями

- Агент не различает серые клетки
- Наблюдение — вектор стен вокруг агента:
$$o(s) = (\text{сверху, снизу, слева, справа})$$
- Для обеих серых клеток: $o = (1, 1, 0, 0)$ — одинаковое наблюдение!




Клеточный мир с одинаковыми наблюдениями

- Агент не различает серые клетки
- Наблюдение — вектор стен вокруг агента:
$$o(s) = (\text{сверху, снизу, слева, справа})$$
- Для обеих серых клеток: $o = (1, 1, 0, 0)$ — одинаковое наблюдение!
- Сравним два подхода:
 - На основе полезности: $\hat{Q}(o, a)$
 - На основе стратегии: $\pi_\theta(a|o)$



Детерминированная стратегия

- Одна из оптимальных **детерминированных** стратегий:
 - двигаться **влево** в обеих серых клетках (красные стрелки)
- В любом случае, агент может застрять и никогда не отыскать целевого состояния
- Основанные на полезности методы находят близкую к детерминированной стратегию (ϵ -жадную)
- В этом случае агент может блуждать по коридору длительное время




Стохастическая стратегия

- Серые клетки: $o = (\underbrace{1}_{\text{сверху}}, \underbrace{1}_{\text{снизу}}, \underbrace{0}_{\text{слева}}, \underbrace{0}_{\text{справа}})$
- Оптимальная **стохастическая** стратегия — двигаться случайно:

$$\pi_{\theta}(\text{влево} \mid o) = 0.5, \quad \pi_{\theta}(\text{вправо} \mid o) = 0.5$$

- Агент достигает цели за небольшое количество шагов с высокой вероятностью
- Методы на основе стратегии позволяют обучить такую стохастическую стратегию




Стохастическая стратегия

- Серые клетки: $o = (\underbrace{1}_{\text{сверху}}, \underbrace{1}_{\text{снизу}}, \underbrace{0}_{\text{слева}}, \underbrace{0}_{\text{справа}})$
- Оптимальная **стохастическая** стратегия — двигаться случайно:

$$\pi_{\theta}(\text{влево} \mid o) = 0.5, \quad \pi_{\theta}(\text{вправо} \mid o) = 0.5$$

- Агент достигает цели за небольшое количество шагов с высокой вероятностью
- Методы на основе стратегии позволяют обучить такую стохастическую стратегию



Примечание: данный пример — случай частичной наблюдаемости (POMDP), а не МППР (MDP).

Параметризация стратегии

Стратегию π_θ параметризуем нейросетью $f_\theta(s)$ (например, несколько MLP слоев). Тип выходного слоя зависит от пространства действий:

Дискретные действия

- К выходу $f_\theta(s)$ применяем softmax:

$$\pi_\theta(a|s) = \text{softmax}(f_\theta(s))_a$$

Непрерывные действия

- $f_\theta(s)$ выдаёт $\mu_\theta(s)$, $\sigma_\theta(s)$:

$$a \sim \mathcal{N}(\mu_\theta(s), \sigma_\theta^2(s))$$

02

Вывод градиента стратегии

Функция полезности стратегии

- Цель: по данной стратегии $\pi_\theta(a|s)$ с параметрами θ , найти наилучшее θ
- Как оценить качество стратегии π_θ ?
- В эпизодических средах максимизируем **ожидаемую отдачу**:

$$J(\theta) = V^{\pi_\theta}(s_0) = \mathbb{E}_{\pi_\theta}[G_0]$$

- Для не эпизодических сред существуют другие формулировки (средняя полезность, среднее вознаграждение за шаг)
- Далее работаем с эпизодическим случаем

Оптимизация стратегии

- Методы поиска стратегии – это алгоритмы оптимизации
- Необходимо найти значение θ , которое максимизирует $J(\theta)$
- Есть методы, **не** использующие градиент стратегии (hill climbing, CMA-ES, ES и т.п.)
- Однако большей эффективности можно добиться с помощью **градиентных методов**
- Будем оптимизировать стратегию методом **градиентного подъема**:

$$\theta_{k+1} = \theta_k + \alpha \nabla_{\theta} J(\theta)|_{\theta_k}$$

- Градиент $\nabla_{\theta} J(\theta)$ называется **градиентом стратегии** (policy gradient)
- Алгоритмы на его основе: VPG, TRPO, PPO, ...

Траектория и полезность стратегии

- Рассмотрим стохастическую параметризованную стратегию $\pi_\theta(a|s)$
- Будем называть **траекторией** цепочку:

$$\tau = (s_0, a_0, r_0, \dots, s_{T-1}, a_{T-1}, r_{T-1}, s_T)$$

- **Отдача** по траектории: $G(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t$, где $\gamma \in [0, 1]$ – коэффициент дисконтирования
- Цель – максимизировать ожидаемую отдачу:

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [G(\tau)]$$

- Для получения $\nabla_\theta J(\theta)$ нужно:
 1. вывести аналитический градиент (в виде мат. ожидания),
 2. оценить его эмпирически по выборке траекторий

Градиент мат. ожидания по параметрам

- Стратегия $\pi_\theta(a|s)$ гладкая по θ
- Хотим найти $\nabla_\theta J(\theta) = \nabla_\theta \mathbb{E}_{\tau \sim \pi_\theta}[G(\tau)]$
- Вероятность траектории $\tau = (s_0, a_0, \dots, s_T)$:

$$P(\tau|\theta) = P_0(s_0) \prod_{t=0}^{T-1} P(s_{t+1}|s_t, a_t) \pi_\theta(a_t|s_t)$$

- $G(\tau)$ не зависит от θ , но распределение $P(\tau|\theta)$ — зависит

Вывод градиента стратегии

$$\nabla_{\theta} J(\theta) = \nabla_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}}[G(\tau)]$$

Вывод градиента стратегии

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \nabla_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}}[G(\tau)] \\ &= \nabla_{\theta} \int_{\tau} P(\tau|\theta) G(\tau) d\tau\end{aligned}$$

раскрытие $\mathbb{E}$

Вывод градиента стратегии

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \nabla_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}}[G(\tau)] \\ &= \nabla_{\theta} \int_{\tau} P(\tau|\theta) G(\tau) d\tau \\ &= \int_{\tau} \nabla_{\theta} P(\tau|\theta) G(\tau) d\tau\end{aligned}$$

раскрытие $\mathbb{E}$

∇_{θ} под интеграл

Вывод градиента стратегии

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \nabla_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}}[G(\tau)] \\ &= \nabla_{\theta} \int_{\tau} P(\tau|\theta) G(\tau) d\tau \\ &= \int_{\tau} \nabla_{\theta} P(\tau|\theta) G(\tau) d\tau \\ &= \int_{\tau} P(\tau|\theta) \frac{\nabla_{\theta} P(\tau|\theta)}{P(\tau|\theta)} G(\tau) d\tau\end{aligned}$$

раскрытие $\mathbb{E}$

∇_{θ} под интеграл

$\times \frac{P}{P}$

Вывод градиента стратегии

$$\nabla_{\theta} J(\theta) = \nabla_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}}[G(\tau)]$$

$$= \nabla_{\theta} \int_{\tau} P(\tau|\theta) G(\tau) d\tau$$

раскрытие $\mathbb{E}$

$$= \int_{\tau} \nabla_{\theta} P(\tau|\theta) G(\tau) d\tau$$

∇_{θ} под интеграл

$$= \int_{\tau} P(\tau|\theta) \frac{\nabla_{\theta} P(\tau|\theta)}{P(\tau|\theta)} G(\tau) d\tau$$

$\times \frac{P}{P}$

$$= \int_{\tau} P(\tau|\theta) \nabla_{\theta} \log P(\tau|\theta) G(\tau) d\tau$$

$$\frac{\nabla f}{f} = \nabla \log f$$

Вывод градиента стратегии

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \nabla_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}}[G(\tau)] \\&= \nabla_{\theta} \int_{\tau} P(\tau|\theta) G(\tau) d\tau && \text{раскрытие } \mathbb{E} \\&= \int_{\tau} \nabla_{\theta} P(\tau|\theta) G(\tau) d\tau && \nabla_{\theta} \text{ под интеграл} \\&= \int_{\tau} P(\tau|\theta) \frac{\nabla_{\theta} P(\tau|\theta)}{P(\tau|\theta)} G(\tau) d\tau && \times \frac{P}{P} \\&= \int_{\tau} P(\tau|\theta) \nabla_{\theta} \log P(\tau|\theta) G(\tau) d\tau && \frac{\nabla f}{f} = \nabla \log f \\&= \mathbb{E}_{\tau \sim \pi_{\theta}}[\nabla_{\theta} \log P(\tau|\theta) G(\tau)] && \text{обратно в } \mathbb{E}\end{aligned}$$

- Градиент выражен как мат. ожидание — можно оценить по выборке!

Вывод градиента стратегии

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \nabla_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}}[G(\tau)] \\&= \nabla_{\theta} \int_{\tau} P(\tau|\theta) G(\tau) d\tau && \text{раскрытие } \mathbb{E} \\&= \int_{\tau} \nabla_{\theta} P(\tau|\theta) G(\tau) d\tau && \nabla_{\theta} \text{ под интеграл} \\&= \int_{\tau} P(\tau|\theta) \frac{\nabla_{\theta} P(\tau|\theta)}{P(\tau|\theta)} G(\tau) d\tau && \times \frac{P}{P} \\&= \int_{\tau} P(\tau|\theta) \nabla_{\theta} \log P(\tau|\theta) G(\tau) d\tau && \frac{\nabla f}{f} = \nabla \log f \\&= \mathbb{E}_{\tau \sim \pi_{\theta}}[\nabla_{\theta} \log P(\tau|\theta) G(\tau)] && \text{обратно в } \mathbb{E}\end{aligned}$$

- Градиент выражен как мат. ожидание — можно оценить по выборке!
- Но $\log P(\tau|\theta)$ содержит динамику среды $P(s'|s, a)$, которую мы не знаем: $\mathbb{E}_{\tau \sim \pi_{\theta}}[\nabla_{\theta} \log P(\tau|\theta) G(\tau)]$

Упрощение: исключение динамики среды

Разберёмся с $\log P(\tau|\theta)$:

$$\mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log P(\tau|\theta) G(\tau)]$$

Упрощение: исключение динамики среды

Разберёмся с $\log P(\tau|\theta)$:

$$\mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log P(\tau|\theta) G(\tau)]$$

► Логарифм произведения:

$$\log P(\tau|\theta) = \log P_0(s_0) + \sum_{t=0}^{T-1} \left(\log P(s_{t+1}|s_t, a_t) + \log \pi_\theta(a_t|s_t) \right)$$

Упрощение: исключение динамики среды

Разберёмся с $\log P(\tau|\theta)$:

$$\mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log P(\tau|\theta) G(\tau)]$$

➤ Логарифм произведения:

$$\log P(\tau|\theta) = \log P_0(s_0) + \sum_{t=0}^{T-1} \left(\log P(s_{t+1}|s_t, a_t) + \log \pi_\theta(a_t|s_t) \right)$$

➤ Динамика среды не зависит от θ :

$$\nabla_\theta \log P(\tau|\theta) = \cancel{\nabla_\theta \log P_0(s_0)} + \sum_{t=0}^{T-1} \left(\cancel{\nabla_\theta \log P(s_{t+1}|s_t, a_t)} + \nabla_\theta \log \pi_\theta(a_t|s_t) \right)$$

Упрощение: исключение динамики среды

Разберёмся с $\log P(\tau|\theta)$:

$$\mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log P(\tau|\theta) G(\tau)]$$

➤ Логарифм произведения:

$$\log P(\tau|\theta) = \log P_0(s_0) + \sum_{t=0}^{T-1} \left(\log P(s_{t+1}|s_t, a_t) + \log \pi_\theta(a_t|s_t) \right)$$

➤ Динамика среды не зависит от θ :

$$\nabla_\theta \log P(\tau|\theta) = \cancel{\nabla_\theta \log P_0(s_0)} + \sum_{t=0}^{T-1} \left(\cancel{\nabla_\theta \log P(s_{t+1}|s_t, a_t)} + \nabla_\theta \log \pi_\theta(a_t|s_t) \right)$$

Подставляем $\nabla_\theta \log P(\tau|\theta)$:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t|s_t) G(\tau) \right]$$

Не нужна модель среды — только градиент логарифма стратегии!


Эмпирическая оценка градиента стратегии

- ▶ Градиент — мат. ожидание $\Rightarrow$ оцениваем по выборке N траекторий $\mathcal{D} = \{\tau_i\}_{i=1}^N$:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

- ▶ Не нужна модель среды! Оценка **несмещенная**, но с **высокой дисперсией**
- ▶ **Интуиция:** чем больше $G(\tau)$, тем сильнее увеличиваем вероятность действий траектории

На рисунке: три траектории τ_1, τ_2, τ_3 из s_0 на условном ландшафте наград.



«Функция потерь» в градиенте стратегии

- ▶ На практике формулируют «функцию потерь», чей градиент совпадает с градиентом стратегии:

$$L(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

«Функция потерь» в градиенте стратегии

- На практике формулируют «функцию потерь», чей градиент совпадает с градиентом стратегии:

$$L(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

- Но это **не** функция потерь в обычном смысле:

«Функция потерь» в градиенте стратегии

- На практике формулируют «функцию потерь», чей градиент совпадает с градиентом стратегии:

$$L(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

- Но это **не** функция потерь в обычном смысле:

1. **Данные зависят от параметров:** выборка получена текущей π_{θ} , а не фиксированным датасетом

«Функция потерь» в градиенте стратегии

- На практике формулируют «функцию потерь», чей градиент совпадает с градиентом стратегии:

$$L(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

- Но это **не** функция потерь в обычном смысле:
 1. **Данные зависят от параметров:** выборка получена текущей π_{θ} , а не фиксированным датасетом
 2. **Не измеряет качество:** в supervised learning $L \downarrow \Rightarrow$ модель лучше; здесь $L \downarrow$ ничего не гарантирует

«Функция потерь» в градиенте стратегии

- На практике формулируют «функцию потерь», чей градиент совпадает с градиентом стратегии:

$$L(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

- Но это **не** функция потерь в обычном смысле:
 1. **Данные зависят от параметров:** выборка получена текущей π_{θ} , а не фиксированным датасетом
 2. **Не измеряет качество:** в supervised learning $L \downarrow \Rightarrow$ модель лучше; здесь $L \downarrow$ ничего не гарантирует
- Множественные шаги градиента на одном батче $L \rightarrow -\infty$, стратегия «переобучается»
- **Вывод:** отслеживайте **среднюю отдачу** $\bar{G}$, а не значение $L(\theta)$

03

Уменьшение дисперсии

Монте-Карло градиент стратегии (REINFORCE)

- Используем полную отдачу $G(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t$ для оценки градиента:

$$\nabla_{\theta} J(\theta) \approx \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G(\tau_i)$$

- Обновляем параметры с помощью стохастического градиентного подъема

Вход: стратегия π_{θ} , γ , шаг α , батч N

1: инициализируем θ

2: **for** итераций $k = 0, 1, 2, \dots$ **do**

13: **end for**

Монте-Карло градиент стратегии (REINFORCE)

- Используем полную отдачу $G(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t$ для оценки градиента:

$$\nabla_{\theta} J(\theta) \approx \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G(\tau_i)$$

- Обновляем параметры с помощью стохастического градиентного подъема

Вход: стратегия π_{θ} , γ , шаг α , батч N

```
1: инициализируем  $\theta$ 
2: for итераций  $k = 0, 1, 2, \dots$  do
3:   for  $i = 1, \dots, N$  do
4:      $s_0 \leftarrow$  начальное состояние
5:     for  $t = 0, \dots, T - 1$  do
6:        $a_t \sim \pi_{\theta}(\cdot | s_t)$ 
7:        $s_{t+1}, r_t \leftarrow$  среда( $s_t, a_t$ )
8:     end for
9:
10:   end for
11:
12:    $\theta \leftarrow \theta + \alpha \nabla_{\theta} J(\theta)$ 
13: end for
```

▷ сбор батча

Монте-Карло градиент стратегии (REINFORCE)

- Используем полную отдачу $G(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t$ для оценки градиента:

$$\nabla_{\theta} J(\theta) \approx \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G(\tau_i)$$

- Обновляем параметры с помощью стохастического градиентного подъема

Вход: стратегия π_{θ} , γ , шаг α , батч N

```
1: инициализируем  $\theta$ 
2: for итераций  $k = 0, 1, 2, \dots$  do
3:   for  $i = 1, \dots, N$  do                                     ▷ сбор батча
4:      $s_0 \leftarrow$  начальное состояние
5:     for  $t = 0, \dots, T - 1$  do
6:        $a_t \sim \pi_{\theta}(\cdot | s_t)$ 
7:        $s_{t+1}, r_t \leftarrow$  среда( $s_t, a_t$ )
8:     end for
9:      $G(\tau_i) \leftarrow \sum_{t=0}^{T-1} \gamma^t r_t$                                      ▷ отдача
10:   end for

13: end for
```

Монте-Карло градиент стратегии (REINFORCE)

- Используем полную отдачу $G(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t$ для оценки градиента:

$$\nabla_{\theta} J(\theta) \approx \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G(\tau_i)$$

- Обновляем параметры с помощью стохастического градиентного подъема

Вход: стратегия π_{θ} , γ , шаг α , батч N

```
1: инициализируем  $\theta$ 
2: for итераций  $k = 0, 1, 2, \dots$  do
3:   for  $i = 1, \dots, N$  do                                     ▷ сбор батча
4:      $s_0 \leftarrow$  начальное состояние
5:     for  $t = 0, \dots, T - 1$  do
6:        $a_t \sim \pi_{\theta}(\cdot | s_t)$ 
7:        $s_{t+1}, r_t \leftarrow$  среда( $s_t, a_t$ )
8:     end for
9:      $G(\tau_i) \leftarrow \sum_{t=0}^{T-1} \gamma^t r_t$                                      ▷ отдача
10:  end for
11:   $\hat{g} \leftarrow \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$ 
13: end for
```

Монте-Карло градиент стратегии (REINFORCE)

- Используем полную отдачу $G(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t$ для оценки градиента:

$$\nabla_{\theta} J(\theta) \approx \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G(\tau_i)$$

- Обновляем параметры с помощью стохастического градиентного подъема

Вход: стратегия π_{θ} , γ , шаг α , батч N

```
1: инициализируем  $\theta$ 
2: for итераций  $k = 0, 1, 2, \dots$  do
3:   for  $i = 1, \dots, N$  do                                     ▷ сбор батча
4:      $s_0 \leftarrow$  начальное состояние
5:     for  $t = 0, \dots, T - 1$  do
6:        $a_t \sim \pi_{\theta}(\cdot | s_t)$ 
7:        $s_{t+1}, r_t \leftarrow$  среда( $s_t, a_t$ )
8:     end for
9:      $G(\tau_i) \leftarrow \sum_{t=0}^{T-1} \gamma^t r_t$                                      ▷ отдача
10:  end for
11:   $\hat{g} \leftarrow \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$ 
12:   $\theta \leftarrow \theta + \alpha \hat{g}$                                      ▷ градиентный подъем
13: end for
```

Проблема дисперсии в градиенте стратегии

- Цель – максимально быстро сойтись к (локальному) оптимуму
- Оценка градиента по траекториям:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

- Оценка несмещенная, но с **высокой дисперсией**

Проблема дисперсии в градиенте стратегии

- Цель – максимально быстро сойтись к (локальному) оптимуму
- Оценка градиента по траекториям:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

- Оценка несмещенная, но с **высокой дисперсией**
- Три способа борьбы с дисперсией:

Проблема дисперсии в градиенте стратегии

- Цель – максимально быстро сойтись к (локальному) оптимуму
- Оценка градиента по траекториям:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

- Оценка несмещенная, но с **высокой дисперсией**
- Три способа борьбы с дисперсией:
 1. использование **временной структуры** MDP (reward-to-go),

Проблема дисперсии в градиенте стратегии

- Цель – максимально быстро сойтись к (локальному) оптимуму
- Оценка градиента по траекториям:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

- Оценка несмещенная, но с **высокой дисперсией**
- Три способа борьбы с дисперсией:
 1. использование **временной структуры** MDP (reward-to-go),
 2. учет **базового уровня** (baseline),

Проблема дисперсии в градиенте стратегии

- Цель – максимально быстро сойтись к (локальному) оптимуму
- Оценка градиента по траекториям:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) G(\tau_i)$$

- Оценка несмещенная, но с **высокой дисперсией**
- Три способа борьбы с дисперсией:
 1. использование **временной структуры** MDP (reward-to-go),
 2. учет **базового уровня** (baseline),
 3. использование **критика** вместо Монте-Карло оценки

Лемма о градиенте логарифма вероятности

- Ключевой результат, обосновывающий будущую отдачу (reward-to-go) и базовый уровень (baseline)

Лемма о мат. ожидании градиента логарифма вероятности

Пусть P_θ – параметризованное распределение случайной величины x . Тогда:

$$\mathbb{E}_{x \sim P_\theta} [\nabla_\theta \log P_\theta(x)] = 0$$

Лемма о градиенте логарифма вероятности

- Ключевой результат, обосновывающий будущую отдачу (reward-to-go) и базовый уровень (baseline)

Лемма о мат. ожидании градиента логарифма вероятности

Пусть P_θ – параметризованное распределение случайной величины x . Тогда:

$$\mathbb{E}_{x \sim P_\theta}[\nabla_\theta \log P_\theta(x)] = 0$$

Доказательство. Все распределения нормированы: $\int_x P_\theta(x) = 1$. Берем градиент:

$$0 = \nabla_\theta \int_x P_\theta(x)$$

Лемма о градиенте логарифма вероятности

- ▶ Ключевой результат, обосновывающий будущую отдачу (reward-to-go) и базовый уровень (baseline)

Лемма о мат. ожидании градиента логарифма вероятности

Пусть P_θ – параметризованное распределение случайной величины x . Тогда:

$$\mathbb{E}_{x \sim P_\theta}[\nabla_\theta \log P_\theta(x)] = 0$$

Доказательство. Все распределения нормированы: $\int_x P_\theta(x) = 1$. Берем градиент:

$$\begin{aligned} 0 &= \nabla_\theta \int_x P_\theta(x) \\ &= \int_x \nabla_\theta P_\theta(x) \end{aligned}$$

∇_θ под интеграл

Лемма о градиенте логарифма вероятности

- ▶ Ключевой результат, обосновывающий будущую отдачу (reward-to-go) и базовый уровень (baseline)

Лемма о мат. ожидании градиента логарифма вероятности

Пусть P_θ – параметризованное распределение случайной величины x . Тогда:

$$\mathbb{E}_{x \sim P_\theta} [\nabla_\theta \log P_\theta(x)] = 0$$

Доказательство. Все распределения нормированы: $\int_x P_\theta(x) = 1$. Берем градиент:

$$\begin{aligned} 0 &= \nabla_\theta \int_x P_\theta(x) \\ &= \int_x \nabla_\theta P_\theta(x) && \nabla_\theta \text{ под интеграл} \\ &= \int_x P_\theta(x) \nabla_\theta \log P_\theta(x) && \text{производная логорифма} \end{aligned}$$

Лемма о градиенте логарифма вероятности

- ▶ Ключевой результат, обосновывающий будущую отдачу (reward-to-go) и базовый уровень (baseline)

Лемма о мат. ожидании градиента логарифма вероятности

Пусть P_θ – параметризованное распределение случайной величины x . Тогда:

$$\mathbb{E}_{x \sim P_\theta}[\nabla_\theta \log P_\theta(x)] = 0$$


Доказательство. Все распределения нормированы: $\int_x P_\theta(x) = 1$. Берем градиент:

$$\begin{aligned} 0 &= \nabla_\theta \int_x P_\theta(x) \\ &= \int_x \nabla_\theta P_\theta(x) && \nabla_\theta \text{ под интеграл} \\ &= \int_x P_\theta(x) \nabla_\theta \log P_\theta(x) && \text{производная логорифма} \\ &= \mathbb{E}_{x \sim P_\theta}[\nabla_\theta \log P_\theta(x)] && \text{определение } \mathbb{E} \quad \square \end{aligned}$$

Будущая отдача: интуиция

Сейчас выбираем прыжок a_t .

Если учитывать уже съеденных мух, удачное прошлое повысит оценку даже неудачного следующего прыжка.



Будущая отдача: интуиция


Сейчас выбираем прыжок a_t .

Если учитывать уже съеденных мух, удачное прошлое повысит оценку даже неудачного следующего прыжка.

$$G(\tau) = \underbrace{R_{<t}}_{\text{прошлое}} + \underbrace{\gamma^t G_t}_{\text{будущее}}$$

$R_{<t} = \sum_{k=0}^{t-1} \gamma^k r_k$ — уже получено.

G_t — отдача начиная с текущего прыжка.



Будущая отдача: интуиция


Сейчас выбираем прыжок a_t .

Если учитывать уже съеденных мух, удачное прошлое повысит оценку даже неудачного следующего прыжка.

$$G(\tau) = \underbrace{R_{<t}}_{\text{прошлое}} + \underbrace{\gamma^t G_t}_{\text{будущее}}$$

$R_{<t} = \sum_{k=0}^{t-1} \gamma^k r_k$ — уже получено.

G_t — отдача начиная с текущего прыжка.



Оцениваем текущий прыжок по наградам, которые ещё могут от него зависеть.

Снижение дисперсии: будущая отдача (reward-to-go)

- В простейшей формуле каждое действие взвешивается полной отдачей:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G(\tau) \right]$$

Снижение дисперсии: будущая отдача (reward-to-go)

- В простейшей формуле каждое действие взвешивается полной отдачей:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G(\tau) \right]$$

- При фиксированной истории h_t прошлые награды $R_{<t}$ уже известны. По лемме:

$$\mathbb{E}_{a_t \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_{<t} \mid h_t] = 0$$

Снижение дисперсии: будущая отдача (reward-to-go)

- В простейшей формуле каждое действие взвешивается полной отдачей:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G(\tau) \right]$$

- При фиксированной истории h_t прошлые награды $R_{<t}$ уже известны. По лемме:

$$\mathbb{E}_{a_t \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_{<t} | h_t] = 0$$

- Подставляем $G(\tau) = R_{<t} + \gamma^t G_t$ и отбрасываем прошлые награды:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{T-1} \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t \right]$$

где $G_t = \sum_{k=t}^{T-1} \gamma^{k-t} r_k$ — **будущая отдача** (reward-to-go).

Снижение дисперсии: будущая отдача (reward-to-go)

- В простейшей формуле каждое действие взвешивается полной отдачей:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G(\tau) \right]$$

- При фиксированной истории h_t прошлые награды $R_{<t}$ уже известны. По лемме:

$$\mathbb{E}_{a_t \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_{<t} | h_t] = 0$$

- Подставляем $G(\tau) = R_{<t} + \gamma^t G_t$ и отбрасываем прошлые награды:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{T-1} \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t \right]$$

где $G_t = \sum_{k=t}^{T-1} \gamma^{k-t} r_k$ — **будущая отдача** (reward-to-go).

- Убираем вклад прошлых наград, не меняя матожидание оценки градиента.

Базовый уровень (baseline)

- Из леммы о градиенте лог-вероятности следует: для любой функции $b(s_t)$, зависящей только от состояния:

$$\mathbb{E}_{a_t \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a_t | s_t) b(s_t)] = 0$$

Базовый уровень (baseline)

- Из леммы о градиенте лог-вероятности следует: для любой функции $b(s_t)$, зависящей только от состояния:

$$\mathbb{E}_{a_t \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a_t | s_t) b(s_t)] = 0$$

- Можно вычитать базовый уровень, не меняя мат. ожидание градиента:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) (G_t - b(s_t)) \right]$$

Базовый уровень (baseline)

- Из леммы о градиенте лог-вероятности следует: для любой функции $b(s_t)$, зависящей только от состояния:

$$\mathbb{E}_{a_t \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a_t | s_t) b(s_t)] = 0$$

- Можно вычитать базовый уровень, не меняя мат. ожидание градиента:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) (G_t - b(s_t)) \right]$$

- Лучший выбор: $b(s_t) \approx V^{\pi_\theta}(s_t)$
- Интерпретация: увеличиваем $\log \pi_\theta(a_t | s_t)$ пропорционально тому, насколько результат **лучше ожидаемого**

Базовый уровень (baseline)

- Из леммы о градиенте лог-вероятности следует: для любой функции $b(s_t)$, зависящей только от состояния:

$$\mathbb{E}_{a_t \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a_t | s_t) b(s_t)] = 0$$

- Можно вычитать базовый уровень, не меняя мат. ожидание градиента:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) (G_t - b(s_t)) \right]$$

- Лучший выбор: $b(s_t) \approx V^{\pi_\theta}(s_t)$
- Интерпретация: увеличиваем $\log \pi_\theta(a_t | s_t)$ пропорционально тому, насколько результат **лучше ожидаемого**
- На практике V^{π_θ} приближаем нейросетью $V_\phi(s_t)$, обучаемой по MSE:

$$\phi_k = \arg \min_{\phi} \mathbb{E}_{s_t, G_t \sim \pi_\theta} [(V_\phi(s_t) - G_t)^2]$$

Варианты оценки градиента стратегии

Меняем сигнал Φ_t , которым взвешиваем градиент логарифма стратегии:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) \Phi_t^{(i)}$$

Оценка

Φ_t

Варианты оценки градиента стратегии

Меняем сигнал Φ_t , которым взвешиваем градиент логарифма стратегии:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) \Phi_t^{(i)}$$

Оценка	Φ_t
Полная отдача	$G(\tau)$

Варианты оценки градиента стратегии

Меняем сигнал Φ_t , которым взвешиваем градиент логарифма стратегии:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) \Phi_t^{(i)}$$

Оценка	Φ_t
Полная отдача	$G(\tau)$
Будущая отдача	G_t

Варианты оценки градиента стратегии

Меняем сигнал Φ_t , которым взвешиваем градиент логарифма стратегии:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) \Phi_t^{(i)}$$

Оценка	Φ_t
Полная отдача	$G(\tau)$
Будущая отдача	G_t
Базовый уровень	$G_t - b(s_t)$

Варианты оценки градиента стратегии

Меняем сигнал Φ_t , которым взвешиваем градиент логарифма стратегии:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) \Phi_t^{(i)}$$

Оценка	Φ_t
Полная отдача	$G(\tau)$
Будущая отдача	G_t
Базовый уровень	$G_t - b(s_t)$
Q-функция	$Q_{\phi}(s_t, a_t)$

Варианты оценки градиента стратегии

Меняем сигнал Φ_t , которым взвешиваем градиент логарифма стратегии:

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) \Phi_t^{(i)}$$

Оценка	Φ_t
Полная отдача	$G(\tau)$
Будущая отдача	G_t
Базовый уровень	$G_t - b(s_t)$
Q-функция	$Q_{\phi}(s_t, a_t)$
TD-ошибка	$\delta_t = r_t + \gamma V_{\phi}(s_{t+1}) - V_{\phi}(s_t)$

Ошибка критика может вносить смещение в оценку градиента.

От отдачи к Q-функции

► Мы уже знаем: $\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t]$

От отдачи к Q-функции

- Мы уже знаем: $\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t]$
- По определению: $Q^{\pi_{\theta}}(s_t, a_t) = \mathbb{E}[G_t \mid s_t, a_t]$

От отдачи к Q-функции

- Мы уже знаем: $\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t]$
- По определению: $Q^{\pi_{\theta}}(s_t, a_t) = \mathbb{E}[G_t \mid s_t, a_t]$
- $\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$ зависит только от $(s_t, a_t) \Rightarrow$ заменяем $G_t \rightarrow Q^{\pi_{\theta}}(s_t, a_t)$

От отдачи к Q-функции

- Мы уже знаем: $\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t]$
- По определению: $Q^{\pi_{\theta}}(s_t, a_t) = \mathbb{E}[G_t | s_t, a_t]$
- $\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$ зависит только от $(s_t, a_t) \Rightarrow$ заменяем $G_t \rightarrow Q^{\pi_{\theta}}(s_t, a_t)$

Градиент стратегии через Q-функцию

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a | s) Q^{\pi_{\theta}}(s, a)]$$

От отдачи к Q-функции

- Мы уже знаем: $\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t]$
- По определению: $Q^{\pi_{\theta}}(s_t, a_t) = \mathbb{E}[G_t | s_t, a_t]$
- $\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$ зависит только от $(s_t, a_t) \Rightarrow$ заменяем $G_t \rightarrow Q^{\pi_{\theta}}(s_t, a_t)$

Градиент стратегии через Q-функцию

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a | s) Q^{\pi_{\theta}}(s, a)]$$

- Но $Q^{\pi_{\theta}}$ неизвестна $\rightarrow$ нужно **оценить** $\rightarrow$ нужен **критик**

04




Актор-критик

Актор-критик: идея

- Алгоритмы **актор-критик** поддерживают два набора параметров:


Актор (θ) — стратегия $\pi_\theta(a|s)$

Критик (ϕ) — оценка $V_\phi(s) \approx V^{\pi_\theta}(s)$



Актор-критик: идея

- Алгоритмы **актор-критик** поддерживают два набора параметров:
Актор (θ) — стратегия $\pi_\theta(a|s)$
Критик (ϕ) — оценка $V_\phi(s) \approx V^{\pi_\theta}(s)$
- Критик подсказывает актору, какие действия были хорошими



Vanilla Policy Gradient

➤ **Преимущество:**

$$A^{\pi_{\theta}}(s, a) = Q^{\pi_{\theta}}(s, a) - V^{\pi_{\theta}}(s)$$

насколько a **лучше среднего** в s

- Оценка: $\hat{A}_t = G_t - V_{\phi}(s_t)$
- Актер (θ) — стратегия
- Критик (ϕ) — $V^{\pi_{\theta}}$

Вход: параметры стратегии θ_0 , параметры критика ϕ_0 , шаг α ; γ

1: **for** итераций $k = 0, 1, 2, \dots$ **do**

8: **end for**

Vanilla Policy Gradient

➤ **Преимущество:**

$$A^{\pi_{\theta}}(s, a) = Q^{\pi_{\theta}}(s, a) - V^{\pi_{\theta}}(s)$$

насколько a **лучше среднего** в s

- Оценка: $\hat{A}_t = G_t - V_{\phi}(s_t)$
- Актер (θ) — стратегия
- Критик (ϕ) — $V^{\pi_{\theta}}$

Вход: параметры стратегии θ_0 , параметры критика ϕ_0 , шаг α ; γ

1: **for** итераций $k = 0, 1, 2, \dots$ **do**

2: Набираем траектории $\mathcal{D}_k = \{\tau_i\}$, выполняя π_{θ_k} ▷ сбор данных

8: **end for**

Vanilla Policy Gradient

➤ **Преимущество:**

$$A^{\pi_{\theta}}(s, a) = Q^{\pi_{\theta}}(s, a) - V^{\pi_{\theta}}(s)$$

насколько a **лучше среднего** в s

➤ Оценка: $\hat{A}_t = G_t - V_{\phi}(s_t)$

➤ Актер (θ) — стратегия

➤ Критик (ϕ) — $V^{\pi_{\theta}}$

Вход: параметры стратегии θ_0 , параметры критика ϕ_0 , шаг α ; γ

1: **for** итераций $k = 0, 1, 2, \dots$ **do**

2: Набираем траектории $\mathcal{D}_k = \{\tau_i\}$, выполняя π_{θ_k}

▷ сбор данных

3: Вычисляем отдачу: $G_t^{(i)} = \sum_{t'=t}^{T-1} \gamma^{t'-t} r_{t'}$

4: Оцениваем преимущество: $\hat{A}_t^{(i)} = G_t^{(i)} - V_{\phi}(s_t)$

8: **end for**

Vanilla Policy Gradient

➤ Преимущество:

$$A^{\pi_{\theta}}(s, a) = Q^{\pi_{\theta}}(s, a) - V^{\pi_{\theta}}(s)$$

насколько a **лучше среднего** в s

➤ Оценка: $\hat{A}_t = G_t - V_{\phi}(s_t)$

➤ Актор (θ) — стратегия

➤ Критик (ϕ) — $V^{\pi_{\theta}}$

Вход: параметры стратегии θ_0 , параметры критика ϕ_0 , шаг α ; γ

1: **for** итераций $k = 0, 1, 2, \dots$ **do**

2: Набираем траектории $\mathcal{D}_k = \{\tau_i\}$, выполняя π_{θ_k}

▷ сбор данных

3: Вычисляем отдачу: $G_t^{(i)} = \sum_{t'=t}^{T-1} \gamma^{t'-t} r_{t'}$

4: Оцениваем преимущество: $\hat{A}_t^{(i)} = G_t^{(i)} - V_{\phi}(s_t)$

5: Оцениваем градиент:

▷ актор

$$\hat{g}_k = \frac{1}{|\mathcal{D}_k|} \sum_{\tau_i \in \mathcal{D}_k} \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \Big|_{\theta_k} \hat{A}_t$$

6: Обновляем стратегию: $\theta_{k+1} \leftarrow \theta_k + \alpha \hat{g}_k$

8: **end for**

Vanilla Policy Gradient

➤ Преимущество:

$$A^{\pi_{\theta}}(s, a) = Q^{\pi_{\theta}}(s, a) - V^{\pi_{\theta}}(s)$$

насколько a **лучше среднего** в s

➤ Оценка: $\hat{A}_t = G_t - V_{\phi}(s_t)$

➤ Актер (θ) — стратегия

➤ Критик (ϕ) — $V^{\pi_{\theta}}$

Вход: параметры стратегии θ_0 , параметры критика ϕ_0 , шаг α ; γ

1: **for** итераций $k = 0, 1, 2, \dots$ **do**

2: Набираем траектории $\mathcal{D}_k = \{\tau_i\}$, выполняя π_{θ_k}

▷ сбор данных

3: Вычисляем отдачу: $G_t^{(i)} = \sum_{t'=t}^{T-1} \gamma^{t'-t} r_{t'}$

4: Оцениваем преимущество: $\hat{A}_t^{(i)} = G_t^{(i)} - V_{\phi}(s_t)$

5: Оцениваем градиент:

▷ актер

$$\hat{g}_k = \frac{1}{|\mathcal{D}_k|} \sum_{\tau_i \in \mathcal{D}_k} \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \Big|_{\theta_k} \hat{A}_t$$

6: Обновляем стратегию: $\theta_{k+1} \leftarrow \theta_k + \alpha \hat{g}_k$

7: Обновляем критика:

▷ критик

$$\phi_{k+1} \leftarrow \arg \min_{\phi} \frac{1}{|\mathcal{D}_k| T} \sum_{\tau_i \in \mathcal{D}_k} \sum_{t=0}^{T-1} \left(V_{\phi}(s_t) - G_t^{(i)} \right)^2$$

8: **end for**

От Монте-Карло критика к TD-критику

- В VPG критик обучается по Монте-Карло оценке G_t :

$$\phi \leftarrow \arg \min_{\phi} \sum_t (V_{\phi}(s_t) - G_t)^2$$

От Монте-Карло критика к TD-критику

- В VPG критик обучается по Монте-Карло оценке G_t :

$$\phi \leftarrow \arg \min_{\phi} \sum_t (V_{\phi}(s_t) - G_t)^2$$

- Проблема: нужны **полные эпизоды**, высокая дисперсия G_t

От Монте-Карло критика к TD-критику

- В VPG критик обучается по Монте-Карло оценке G_t :

$$\phi \leftarrow \arg \min_{\phi} \sum_t (V_{\phi}(s_t) - G_t)^2$$

- Проблема: нужны **полные эпизоды**, высокая дисперсия G_t
- Идея: обучать критика с помощью **TD-обновлений** (как в лекции 3):

$$\phi \leftarrow \phi + \beta (r_t + \gamma V_{\phi}(s_{t+1}) - V_{\phi}(s_t)) \nabla_{\phi} V_{\phi}(s_t)$$

От Монте-Карло критика к TD-критику

- В VPG критик обучается по Монте-Карло оценке G_t :

$$\phi \leftarrow \arg \min_{\phi} \sum_t (V_{\phi}(s_t) - G_t)^2$$

- Проблема: нужны **полные эпизоды**, высокая дисперсия G_t
- Идея: обучать критика с помощью **TD-обновлений** (как в лекции 3):

$$\phi \leftarrow \phi + \beta (r_t + \gamma V_{\phi}(s_{t+1}) - V_{\phi}(s_t)) \nabla_{\phi} V_{\phi}(s_t)$$

- Преимущества TD-критика:
 - обновление **на каждом шаге**, не дожидаясь конца эпизода
 - **меньшая дисперсия**, но вносит смещение
 - работает в **не эпизодических** средах

Алгоритм QAC

- Отличие от VPG: критик оценивает $Q_\phi(s, a)$ вместо $V_\phi(s)$
- Критик обучается **TD-обновлениями** на каждом шаге
- $\Phi_t = Q_\phi(s_t, a_t)$ в градиенте стратегии

Вход: параметры стратегии θ_0 , критика ϕ_0 , шаги $\alpha, \beta; \gamma$

1: **for** итераций $k = 0, 1, 2, \dots$ **do**

9: **end for**

Алгоритм QAC

- Отличие от VPG: критик оценивает $Q_\phi(s, a)$ вместо $V_\phi(s)$
- Критик обучается **TD-обновлениями** на каждом шаге
- $\Phi_t = Q_\phi(s_t, a_t)$ в градиенте стратегии

Вход: параметры стратегии θ_0 , критика ϕ_0 , шаги $\alpha, \beta; \gamma$

1: **for** итераций $k = 0, 1, 2, \dots$ **do**

2: Набираем траектории $\mathcal{D}_k = \{\tau_i\}$, выполняя π_{θ_k}

▷ сбор данных

9: **end for**

Алгоритм QAC

- Отличие от VPG: критик оценивает $Q_\phi(s, a)$ вместо $V_\phi(s)$
- Критик обучается **TD-обновлениями** на каждом шаге
- $\Phi_t = Q_\phi(s_t, a_t)$ в градиенте стратегии

Вход: параметры стратегии θ_0 , критика ϕ_0 , шаги $\alpha, \beta; \gamma$

```
1: for итераций  $k = 0, 1, 2, \dots$  do
2:   Набираем траектории  $\mathcal{D}_k = \{\tau_i\}$ , выполняя  $\pi_{\theta_k}$ 
3:   for каждого шага  $(s_t, a_t, r_t, s_{t+1})$  в  $\mathcal{D}_k$  do
4:      $\delta_t \leftarrow r_t + \gamma Q_\phi(s_{t+1}, a_{t+1}) - Q_\phi(s_t, a_t)$ 
5:      $\phi \leftarrow \phi + \beta \delta_t \nabla_\phi Q_\phi(s_t, a_t)$ 
6:   end for
```

▷ сбор данных

▷ TD-ошибка
▷ критик

```
9: end for
```

Алгоритм QAC

- Отличие от VPG: критик оценивает $Q_\phi(s, a)$ вместо $V_\phi(s)$
- Критик обучается **TD-обновлениями** на каждом шаге
- $\Phi_t = Q_\phi(s_t, a_t)$ в градиенте стратегии

Вход: параметры стратегии θ_0 , критика ϕ_0 , шаги $\alpha, \beta; \gamma$

```
1: for итераций  $k = 0, 1, 2, \dots$  do
2:   Набираем траектории  $\mathcal{D}_k = \{\tau_i\}$ , выполняя  $\pi_{\theta_k}$ 
3:   for каждого шага  $(s_t, a_t, r_t, s_{t+1})$  в  $\mathcal{D}_k$  do
4:      $\delta_t \leftarrow r_t + \gamma Q_\phi(s_{t+1}, a_{t+1}) - Q_\phi(s_t, a_t)$ 
5:      $\phi \leftarrow \phi + \beta \delta_t \nabla_\phi Q_\phi(s_t, a_t)$ 
6:   end for
7:   Оцениваем градиент:
```

▷ сбор данных

▷ TD-ошибка
▷ критик

▷ актор

$$\hat{g}_k = \frac{1}{|\mathcal{D}_k|} \sum_{\tau_i \in \mathcal{D}_k} \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) \Big|_{\theta_k} Q_\phi(s_t, a_t)$$

```
8:   Обновляем стратегию:  $\theta_{k+1} \leftarrow \theta_k + \alpha \hat{g}_k$ 
9: end for
```

Смещенность и совместимые функции аппроксимации

- Аппроксимация Q_ϕ приводит к **смещению** оценки градиента

Смещенность и совместимые функции аппроксимации

- Аппроксимация Q_ϕ приводит к **смещению** оценки градиента
- Можно ли выбрать аппроксиматор, который сохраняет точный градиент?

Смещенность и совместимые функции аппроксимации

- Аппроксимация Q_ϕ приводит к **смещению** оценки градиента
- Можно ли выбрать аппроксиматор, который сохраняет точный градиент?

Теорема о совместимой функции аппроксимации

Если выполнены два условия:

1. аппроксиматор **совместим** со стратегией: $\nabla_\phi Q_\phi(s, a) = \nabla_\theta \log \pi_\theta(a|s)$,
2. параметры минимизируют MSE: $\mathbb{E}_{\pi_\theta} [(Q^{\pi_\theta}(s, a) - Q_\phi(s, a))^2]$,

тогда градиент стратегии **в точности** равен

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(a|s) Q_\phi(s, a)]$$

Оценка функции преимущества через TD-ошибку

- Функция преимущества существенно уменьшает дисперсию:

$$A^{\pi_{\theta}}(s, a) = Q^{\pi_{\theta}}(s, a) - V^{\pi_{\theta}}(s)$$

Оценка функции преимущества через TD-ошибку

- Функция преимущества существенно уменьшает дисперсию:

$$A^{\pi_{\theta}}(s, a) = Q^{\pi_{\theta}}(s, a) - V^{\pi_{\theta}}(s)$$

- Ключевое наблюдение: для истинной $V^{\pi_{\theta}}$, TD-ошибка

$$\delta_t = r_t + \gamma V^{\pi_{\theta}}(s_{t+1}) - V^{\pi_{\theta}}(s_t)$$

является **несмещенной оценкой преимущества**:

Оценка функции преимущества через TD-ошибку

- Функция преимущества существенно уменьшает дисперсию:

$$A^{\pi_{\theta}}(s, a) = Q^{\pi_{\theta}}(s, a) - V^{\pi_{\theta}}(s)$$

- Ключевое наблюдение: для истинной $V^{\pi_{\theta}}$, TD-ошибка

$$\delta_t = r_t + \gamma V^{\pi_{\theta}}(s_{t+1}) - V^{\pi_{\theta}}(s_t)$$

является **несмещенной оценкой преимущества**:

$$\mathbb{E}_{\pi_{\theta}}[\delta_t | s_t, a_t] = \mathbb{E}_{\pi_{\theta}}[r_t + \gamma V^{\pi_{\theta}}(s_{t+1}) | s_t, a_t] - V^{\pi_{\theta}}(s_t)$$

Оценка функции преимущества через TD-ошибку

- Функция преимущества существенно уменьшает дисперсию:

$$A^{\pi_{\theta}}(s, a) = Q^{\pi_{\theta}}(s, a) - V^{\pi_{\theta}}(s)$$

- Ключевое наблюдение: для истинной $V^{\pi_{\theta}}$, TD-ошибка

$$\delta_t = r_t + \gamma V^{\pi_{\theta}}(s_{t+1}) - V^{\pi_{\theta}}(s_t)$$

является **несмещенной оценкой преимущества**:

$$\begin{aligned}\mathbb{E}_{\pi_{\theta}}[\delta_t | s_t, a_t] &= \mathbb{E}_{\pi_{\theta}}[r_t + \gamma V^{\pi_{\theta}}(s_{t+1}) | s_t, a_t] - V^{\pi_{\theta}}(s_t) \\ &= Q^{\pi_{\theta}}(s_t, a_t) - V^{\pi_{\theta}}(s_t) = A^{\pi_{\theta}}(s_t, a_t)\end{aligned}$$

Оценка функции преимущества через TD-ошибку

- Функция преимущества существенно уменьшает дисперсию:

$$A^{\pi\theta}(s, a) = Q^{\pi\theta}(s, a) - V^{\pi\theta}(s)$$

- Ключевое наблюдение: для истинной $V^{\pi\theta}$, TD-ошибка

$$\delta_t = r_t + \gamma V^{\pi\theta}(s_{t+1}) - V^{\pi\theta}(s_t)$$

является **несмещенной оценкой преимущества**:

$$\begin{aligned}\mathbb{E}_{\pi\theta}[\delta_t | s_t, a_t] &= \mathbb{E}_{\pi\theta}[r_t + \gamma V^{\pi\theta}(s_{t+1}) | s_t, a_t] - V^{\pi\theta}(s_t) \\ &= Q^{\pi\theta}(s_t, a_t) - V^{\pi\theta}(s_t) = A^{\pi\theta}(s_t, a_t)\end{aligned}$$

- На практике используем аппроксимацию: $\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$
- Достаточно **одного** набора параметров ϕ (для V_ϕ)

Оценка функции преимущества через TD-ошибку

- Функция преимущества существенно уменьшает дисперсию:

$$A^{\pi_{\theta}}(s, a) = Q^{\pi_{\theta}}(s, a) - V^{\pi_{\theta}}(s)$$

- Ключевое наблюдение: для истинной $V^{\pi_{\theta}}$, TD-ошибка

$$\delta_t = r_t + \gamma V^{\pi_{\theta}}(s_{t+1}) - V^{\pi_{\theta}}(s_t)$$

является **несмещенной оценкой преимущества**:

$$\begin{aligned}\mathbb{E}_{\pi_{\theta}}[\delta_t | s_t, a_t] &= \mathbb{E}_{\pi_{\theta}}[r_t + \gamma V^{\pi_{\theta}}(s_{t+1}) | s_t, a_t] - V^{\pi_{\theta}}(s_t) \\ &= Q^{\pi_{\theta}}(s_t, a_t) - V^{\pi_{\theta}}(s_t) = A^{\pi_{\theta}}(s_t, a_t)\end{aligned}$$

- На практике используем аппроксимацию: $\delta_t = r_t + \gamma V_{\phi}(s_{t+1}) - V_{\phi}(s_t)$
- Достаточно **одного** набора параметров ϕ (для V_{ϕ})
- Градиент стратегии: $\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \delta_t]$

Выводы: Семейство алгоритмов актор-критик

- Градиент стратегии в алгоритмах актор-критик:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) G_t]$$

REINFORCE

Выводы: Семейство алгоритмов актор-критик

- Градиент стратегии в алгоритмах актор-критик:

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{G}_t] \\ &= \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{Q}_{\phi}(s, a)]\end{aligned}$$

REINFORCE
Q Actor-Critic

Выводы: Семейство алгоритмов актор-критик

- Градиент стратегии в алгоритмах актор-критик:

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{G}_t] \\ &= \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{Q}_{\phi}(s, a)] \\ &= \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{\hat{A}}_t]\end{aligned}$$

REINFORCE
Q Actor-Critic
Advantage AC

Выводы: Семейство алгоритмов актор-критик

- Градиент стратегии в алгоритмах актор-критик:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{G}_t]$$

$$= \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{Q}_{\phi}(s, a)]$$

$$= \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{\hat{A}}_t]$$

$$= \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{\delta}_t]$$

REINFORCE

Q Actor-Critic

Advantage AC

TD Actor-Critic

Выводы: Семейство алгоритмов актор-критик

- Градиент стратегии в алгоритмах актор-критик:

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{G}_t] && \text{REINFORCE} \\ &= \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{Q}_{\phi}(s, a)] && \text{Q Actor-Critic} \\ &= \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{\hat{A}}_t] && \text{Advantage AC} \\ &= \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) \textcolor{red}{\delta}_t] && \text{TD Actor-Critic}\end{aligned}$$

- Каждый вариант может быть использован в стохастическом градиентном подъеме
- Критик оценивает $Q^{\pi_{\theta}}(s, a)$, $V^{\pi_{\theta}}(s)$ или $A^{\pi_{\theta}}(s, a)$ с помощью MC или TD

Вопросы?

Энтропийная регуляризация

- Проблема: градиент стратегии может привести к преждевременной сходимости к **детерминированной** стратегии

Энтропийная регуляризация

- Проблема: градиент стратегии может привести к преждевременной сходимости к **детерминированной** стратегии
- Решение: добавить бонус за **энтропию** стратегии:

$$L = L_{\text{pg}} + c \cdot \mathcal{H}[\pi_{\theta}(\cdot|s)], \quad \mathcal{H}[\pi] = - \sum_a \pi(a|s) \log \pi(a|s)$$

Энтропийная регуляризация

- Проблема: градиент стратегии может привести к преждевременной сходимости к **детерминированной** стратегии
- Решение: добавить бонус за **энтропию** стратегии:

$$L = L_{\text{pg}} + c \cdot \mathcal{H}[\pi_{\theta}(\cdot|s)], \quad \mathcal{H}[\pi] = - \sum_a \pi(a|s) \log \pi(a|s)$$

- Эффекты:
 - поощряет исследование во время обучения,
 - предотвращает коллапс стратегии,
 - стабилизирует процесс обучения
- Вспомним затемненный клеточный мир: стохастическая стратегия лучше!

Энтропийная регуляризация

- Проблема: градиент стратегии может привести к преждевременной сходимости к **детерминированной** стратегии
- Решение: добавить бонус за **энтропию** стратегии:

$$L = L_{\text{pg}} + c \cdot \mathcal{H}[\pi_{\theta}(\cdot|s)], \quad \mathcal{H}[\pi] = - \sum_a \pi(a|s) \log \pi(a|s)$$

- Эффекты:
 - поощряет исследование во время обучения,
 - предотвращает коллапс стратегии,
 - стабилизирует процесс обучения
- Вспомним затемненный клеточный мир: стохастическая стратегия лучше!
- Комбинированная функция потерь актер-критика:

$$L = \underbrace{-\hat{\mathbb{E}}_t \left[\log \pi_{\theta}(a_t|s_t) \hat{A}_t \right]}_{L_{\text{policy}}} + c_1 \underbrace{\hat{\mathbb{E}}_t \left[(V_{\phi}(s_t) - G_t)^2 \right]}_{L_{\text{value}}} - c_2 \underbrace{\hat{\mathbb{E}}_t [\mathcal{H}[\pi_{\theta}(\cdot|s_t)]]}_{L_{\text{entropy}}}$$

- Используется в A3C, PPO, SAC и большинстве современных алгоритмов